



UNIVERSIDAD
DE GRANADA

TRABAJO FIN DE GRADO
INGENIERÍA INFORMÁTICA

Estudio e implementación paralela de métodos explícitos multipaso

Resolución de Ecuaciones de Advección-Reacción-Difusión

Autor

José Manuel Navarro Cuartero

Director

José Miguel Mantas Ruiz



ESCUELA TÉCNICA SUPERIOR DE INGENIERÍAS INFORMÁTICA Y DE
TELECOMUNICACIÓN

Granada, Septiembre de 2026

Estudio e implementación paralela de métodos explícitos multipaso para la resolución de ecuaciones de Advección-Reacción-Difusión

José Manuel Navarro Cuartero

Palabras clave: Métodos Numéricos, Ecuaciones Diferenciales Ordinarias, Paralelismo, Runge-Kutta, Adams-Bashforth, Adams-Bashforth-Moulton, CUDA, OpenMP

Resumen

En este Trabajo de Fin de Grado se realiza una investigación en el mundo de las ecuaciones diferenciales ordinarias y los métodos numéricos que se utilizan para alcanzar soluciones aproximadas a las mismas a través de la computación.

Para este fin, se estudian tres familias de métodos de resolución distintos, Runge-Kutta, Adams-Bashforth, y Adams-Bashforth-Moulton, y se implementan. A partir de este punto, se plantean dos tecnologías diferentes que permiten paralelizar el código en busca de una ganancia en tiempo.

La primera de éstas es OpenMP, que explota el paralelismo sobre CPUs multinúcleo, en el cual se implementan y se comparan dos estrategias de paralelización complementarias. Y la segunda es CUDA, que aprovecha el paralelismo masivo de las tarjetas gráficas modernas de NVIDIA.

Partiendo de una serie de algoritmos secuenciales y modelos matemáticos, se implementan y paralelizan con ambas, se realizan mediciones, y se analizan los resultados de tiempo.

Study and parallel implementation of multistep semi-implicit methods: Solving advection-reaction-diffusion equations

José Manuel Navarro Cuartero

Keywords: Numerical Methods, Ordinary Differential Equations, Parallelism, Runge-Kutta, Adams-Bashforth, Adams-Bashforth-Moulton, CUDA, OpenMP

Abstract **RE-TRADUCIR**

In this Bachelor's Thesis, an investigation is carried out into the field of ordinary differential equations and the numerical methods used to obtain approximate solutions to them through computation.

To this end, three different solution methods are studied and implemented; Runge-Kutta, Adams-Bashforth, and Adams-Bashforth-Moulton. From this point, two different technologies are introduced to parallelize the code in pursuit of performance gains.

The first of these is OpenMP, which enables parallelism on multicore CPUs and in which two opposing parallelization strategies are implemented and compared. The second is CUDA, which leverages the massive parallel computing capabilities of modern GPUs.

Starting from a series of sequential problems, the methods are implemented and parallelized using both technologies, and execution time measurements are performed.

Yo, **José Manuel Navarro Cuartero**, alumno de la titulación **Grado en Ingeniería Informática** de la **Escuela Técnica Superior de Ingenierías Informática y de Telecomunicación de la Universidad de Granada**, con DNI 75896777C, autorizo la ubicación de la siguiente copia de mi Trabajo Fin de Grado en la biblioteca del centro para que pueda ser consultada por las personas que lo deseen.

Fdo: José Manuel Navarro Cuartero

Granada a 4 de Septiembre de 2026.

D. **José Miguel Mantas Ruiz**, Profesor del Departamento de Lenguajes y Sistemas Informáticos de la Universidad de Granada.

Informa:

Que el presente trabajo, titulado **Estudio e implementación paralela de métodos explícitos multipaso para la Resolución de Ecuaciones de Advección-Reacción-Difusión**, ha sido realizado bajo su supervisión por **José Manuel Navarro Cuartero**, y autorizo la defensa de dicho trabajo ante el tribunal que corresponda.

Y para que conste, expide y firma el presente informe en Granada a 4 de Septiembre de 2026.

El director:

José Miguel Mantas Ruiz

Agradecimientos

Quiero agradecer a mi tutor su guía y su paciencia a lo largo de este largo camino. También a mi familia y mis amigos, por haberme acompañado de Cádiz a Granada y vuelta. Y a mi pareja, sin la cual yo no estaría aquí hoy día.

Índice

1. Introducción	1
2. Conceptos previos y tecnologías empleadas	4
2.1. Métodos Numéricos y Ecuaciones Diferenciales Ordinarias . .	5
2.2. Tipos de métodos numéricos	6
2.3. Método de Euler	7
2.4. Paralelización	9
2.5. Métodos de Runge-Kutta	14
2.6. Métodos de Adams-Bashforth	16
2.7. Métodos de Adams-Bashforth-Moulton	18
2.8. Problemas de prueba	21
2.9. OpenMP	21
2.10. CUDA	22
3. Implementación Multihebra	27
3.1. Implementación Secuencial	27
3.2. Paralelismo por Operaciones	30
3.3. Paralelismo por Componentes	31
3.4. Resultados experimentales	33
4. Implementación para GPU	39
4.1. Implementación	39
4.2. Resultados Experimentales	44
4.3. Uso de CUDA Graphs	48
4.4. Shuffles y Grids multidimensionales	51
5. Planificación	55
6. Código fuente	57

Capítulo 1

Introducción

Los **métodos numéricos** forman un conjunto de herramientas matemáticas cuyo propósito es aproximar soluciones allí donde las técnicas analíticas no alcanzan, ya sea debido a que la ecuación no admite solución cerrada, a que su forma es demasiado compleja o a que obtener la solución exacta sería inviable en términos de tiempo o recursos computacionales [Griffiths and Higham, 2010]. En la práctica científica moderna, casi todos los modelos relevantes, físicos, biológicos, económicos, o de ingeniería, acaban desembocando en ecuaciones que describen cómo evoluciona un sistema, y esas ecuaciones rara vez pueden resolverse de forma analítica. Por eso, los métodos numéricos no son solo una alternativa; son el lenguaje cotidiano de la simulación y el cálculo aplicado.

Dentro de este ámbito de trabajo, las **ecuaciones diferenciales** ocupan un lugar central. Una ecuación diferencial es una relación entre una función desconocida y sus derivadas, y aparece siempre que un fenómeno depende de cómo cambia una cantidad respecto a otra: la velocidad de un objeto, la concentración de una sustancia, la temperatura en un punto, el crecimiento de una población. Resolver una ecuación diferencial significa encontrar la función que satisface esa relación, pero en la mayoría de los casos esa función no puede escribirse de forma exacta. Incluso cuando existe una solución analítica, puede ser tan complicada que trabajar con ella resulte poco práctico. Por eso, recurrimos a métodos numéricos que construyen aproximaciones controladas y útiles.

Por su lado, las ecuaciones de **Advección–Reacción–Difusión** (ADR) son modelos matemáticos que describen cómo evoluciona en el espacio y en el tiempo una cantidad física, química o biológica cuando está sometida simultáneamente a tres procesos fundamentales: transporte, mezcla y transformación interna. Son una de las familias de ecuaciones en derivadas parciales más utilizadas en ciencia e ingeniería porque capturan dinámicas muy complejas de forma compacta y realista. Y si las ADR se discretizan en el espacio [Hairer et al., 1993], conseguimos los sistemas de **Ecuaciones**

Diferenciales Ordinarias (EDOs) que buscamos.

El caso más habitual suelen ser los **Problemas de Valor Inicial** (PVI) para EDOs. En un PVI no solo se especifica la EDO, sino también el valor de la solución en un punto concreto. Esa condición inicial fija la trayectoria que debe seguir la solución y permite avanzar paso a paso, desde el punto conocido hacia los siguientes valores [Heath, 2002]. Los métodos numéricos toman ese valor inicial y, mediante un proceso iterativo, generan una secuencia de aproximaciones en puntos espaciados en la variable independiente, que representa generalmente el tiempo. Cada paso intenta reproducir el comportamiento de la solución real dentro de un intervalo pequeño, y la calidad de esa aproximación depende del método elegido y del tamaño del paso.

Existen muchas formas de avanzar de un punto al siguiente, y cada una representa un compromiso entre precisión, estabilidad, coste computacional, y tiempo de ejecución. Es en este último punto en el que nos centraremos en los siguientes capítulos, ya que si bien para problemas pequeños, algo tan simple como el método de Euler explícito podría bastarnos, posteriormente plantearemos problemas mucho más complejos, que requerirán soluciones que estén a la altura. Por tanto, no se trata solamente de hallar una solución, sino de hacerlo de forma rápida, eficiente, y con la suficiente precisión.

Para esto comenzaremos poniendo en contexto qué son los métodos numéricos y las EDOs, además de distinguir entre diversos tipos de métodos numéricos. También deberemos comprender la naturaleza de las dos tecnologías que implementaremos en nuestra búsqueda del paralelismo y la reducción de los tiempos de ejecución, a saber, **OpenMP** y **CUDA**, paralelismo a nivel de CPU y GPU. También deberemos familiarizarnos extensamente con tres familias de métodos de resolución numérica en particular, y con los órdenes de convergencia de los mismos. Usaremos **Runge-Kutta Explícito** (de un solo paso), **Adams-Bashforth**, y **Adams-Bashforth-Moulton**, explícitos y multipaso. Veremos sus ventajas y desventajas a la hora de elegir uno frente a otro.

Teniendo todo esto en cuenta, partiremos de cuatro problemas que representan diferentes sistemas de EDOs que modelan ADR, cuya implementación secuencial y soluciones esperadas ya conocemos de forma previa, y aplicaremos para su resolución los tres métodos numéricos mencionados, que a su vez implementaremos con las dos tecnologías para paralelizar. Además, dentro de cada tecnología probaremos las distintas herramientas que ponen a nuestra disposición para enfocar la resolución de cada problema desde prismas diferentes.

Objetivos

El primer objetivo de este trabajo consiste en adquirir una base sólida de todos los conceptos que forman el núcleo del estudio: los métodos numéricos, las ecuaciones diferenciales ordinarias, los problemas de valor inicial y las ecuaciones de Advección–Reacción–Difusión. Antes de abordar cualquier implementación, es imprescindible dominar el marco teórico que sustenta la resolución numérica de EDOs. Esta familiarización no se limita a conocer definiciones, sino que implica comprender la lógica interna de cada método, y las razones por las que ciertas técnicas resultan más adecuadas que otras en contextos específicos.

El segundo objetivo es profundizar en el estudio de las dos tecnologías de paralelización que se emplearán en el desarrollo del proyecto: OpenMP y CUDA. Ambas representan paradigmas distintos de computación paralela, uno orientado a la explotación del paralelismo multinúcleo en CPU y el otro al paralelismo masivo en GPU. El propósito es aprender a utilizar cada tecnología de forma eficiente, entender sus modelos de ejecución, sus mecanismos de sincronización y las herramientas que proporcionan para distribuir el trabajo.

El tercer objetivo se centra en la implementación rigurosa de los métodos numéricos y de los problemas seleccionados, garantizando que el código sea correcto, estable y funcional tanto en su versión secuencial como en sus versiones paralelas. Una vez completada la implementación, el siguiente objetivo es realizar mediciones exhaustivas del rendimiento, comparando tiempos de ejecución, escalabilidad y eficiencia entre las distintas tecnologías y métodos numéricos. Finalmente, el trabajo culmina con un análisis crítico de los resultados obtenidos, evaluando qué estrategias ofrecen mejores prestaciones, cómo se comportan los métodos ante distintos problemas y qué conclusiones pueden extraerse.

Capítulo 2

Conceptos previos y tecnologías empleadas

Este capítulo establece los fundamentos teóricos necesarios para comprender el resto del trabajo, comenzando por los métodos numéricos y las ecuaciones diferenciales ordinarias. Se explica qué es una EDO, cómo se formula un problema de valor inicial y por qué es necesario discretizar el tiempo para poder resolver estas ecuaciones mediante algoritmos computacionales. A partir de ejemplos sencillos, como el método de Euler, se introduce la idea de aproximar soluciones mediante pasos sucesivos.

A continuación, el capítulo profundiza en la clasificación de los métodos numéricos, distinguiendo entre métodos explícitos e implícitos, así como entre métodos de un solo paso y métodos multipaso. Se presentan en detalle las familias de Runge–Kutta y Adams–Bashforth, explicando su formulación, sus propiedades y su aplicación práctica en el contexto de la resolución de EDOs. También se introduce el método predictor–corrector Adams–Bashforth–Moulton, que combina la rapidez de un predictor explícito con la estabilidad de un corrector implícito. Todo ello se acompaña de expresiones matemáticas, esquemas de cálculo y pseudocódigo que permiten entender cómo se implementarán posteriormente estos métodos en las versiones secuencial y paralela del proyecto.

Finalmente, el capítulo aborda los conceptos fundamentales de paralelización que serán necesarios para las implementaciones con OpenMP y CUDA. Se explican los distintos modelos de paralelismo, la diferencia entre concurrencia y paralelismo real, y métricas como el speedup y la eficiencia, que permitirán evaluar el rendimiento de las versiones paralelas. Con ello, el capítulo proporciona el marco conceptual que justifica la necesidad de paralelizar los métodos numéricos y prepara el terreno para las implementaciones detalladas que se desarrollarán en los capítulos siguientes.

2.1. Métodos Numéricos y Ecuaciones Diferenciales Ordinarias

Una ecuación diferencial es aquella que relaciona una función ($f(x)$ ó y), sus variables (x) y sus derivadas ($f'(x)$, dy/dx ó y'). Para resolver una ecuación diferencial se debe encontrar una función que satisfaga dicha ecuación. Dentro de las ecuaciones diferenciales nos encontramos las ecuaciones diferenciales ordinarias (EDOs), que contienen derivadas respecto a **una sola variable independiente**. Más adelante nos centraremos en este tipo en particular. En oposición a éstas estarían las ecuaciones en derivadas parciales, en las que la función $f(x)$ depende de más variables independientes [Molero et al., 2007].

El orden de una ecuación diferencial equivale al orden de la mayor derivada que aparece en la ecuación. Además, será lineal cuando la variable dependiente y todas sus derivadas son de primer grado (no puede haber $f(x)^2$), y los coeficientes de la variable dependiente y sus derivadas dependen de la variable independiente.

A modo de primer ejemplo podríamos considerar un problema de valor inicial para EDO ordinaria de primer orden como:

$$\frac{dy}{dt} = -2y, y(0) = 1 \quad (2.1)$$

Donde además de la EDO, se nos está dando su valor inicial. En este caso en particular, sabemos de forma analítica que su solución exacta es $y(t) = e^{-2t}$, y podríamos por tanto calcular cualquier $y(t_n) = y_n$ que deseemos para cualquier t_n en el dominio del problema. No obstante, si por cualquier razón no pudiéramos resolverla analíticamente deberíamos recurrir a los métodos numéricos. A través de ellos, y partiendo del valor $y(t_0)$ que se nos proporciona, calcularíamos $y(t_1) = y(t_0 + \Delta t)$, después $y(t_2) = y(t_1 + \Delta t)$, y continuaríamos de forma iterativa hasta llegar al valor $y(t_f)$ que busquemos como estado final.

En este proceso, discretizamos la variable t en N puntos igualmente espaciados. Cuando hablamos de **discretización en el tiempo**, estamos hablando de un concepto clave en el tratamiento numérico de EDOs. En el mundo real, el tiempo t es una variable continua que puede tomar cualquier valor dentro del intervalo que se esté considerando, y las ecuaciones que describen la evolución de un sistema lo hacen mediante derivadas respecto a t . Para poder trabajar con estas ecuaciones, debemos convertir ese eje continuo en una sucesión de instantes discretos. La discretización en el tiempo consiste en sustituir el tiempo por una secuencia de puntos $t_0, t_1, \dots, t_f$, separados por un tamaño de paso Δt , y en reemplazar las derivadas por aproximaciones que relacionan los valores de la solución en esos instantes [Kim, 2026].

Para aproximar la solución de EDOs con valor inicial podríamos utilizar, por ejemplo, el método de Euler, del que hablaremos más adelante. Antes de

ello podemos entrar en algo más de detalle respecto a algunos otros conceptos que iremos usando.

2.2. Tipos de métodos numéricos

Podemos dividir a los métodos en dos grandes grupos, explícitos, e implícitos. La división se hará en función de cómo se consigue el siguiente paso, es decir, de cómo obtenemos $y(t_n + \Delta t) = y_{n+1}$ a partir de $y(t_n) = y_n$; de si aparecen valores futuros o no en la fórmula que lo calcula. Tendremos como **expresión general** la siguiente: [Molero et al., 2007]

$$y_{n+1} = y_n + \Phi(t_n, y_n, y_{n+1}, \dots, y_{n-k} \Delta t) \quad (2.2)$$

En la cual será la función incremento Φ la que dirima a cuál de los grupos pertenece el método con el que estemos trabajando.

- **Métodos explícitos:** son aquellos en los que el siguiente término se puede obtener directamente, sólo haciendo cálculos con datos de los que ya se dispone. Dicho de otra forma, son aquellos en los que y_{n+1} no aparece en Φ , sólo aparece en la parte izquierda de la ecuación. Entre ellos nos encontraremos el método de Euler explícito, Runge-Kutta explícito, o Adams-Bashforth, veremos los tres posteriormente. Los métodos explícitos suelen ser más fáciles de implementar, ya que no requieren resolver ecuaciones no lineales, y suelen ser más rápidos. Por otro lado, tienden a ser menos estables, especialmente en problemas mal condicionados (*stiff*).
- **Métodos Implícitos:** aquellos en los que y_{n+1} sí aparece en la parte de la derecha de la igualdad, lo cual nos obligaría a resolver una ecuación que podrá ser, o no, lineal. Estos métodos son muy estables, y son más adecuados para resolver problemas mal condicionados (*stiff*). Como parte negativa tienen que requieren resolver ecuaciones en cada paso, y a veces de forma iterativa, lo que los acaba haciendo mucho más costosos computacionalmente aunque permiten usar tamaños de paso (Δt) altos en problemas *stiff*. Entre ellos nos encontramos algunos métodos como el Euler implícito, Adams-Moulton, o la familia de los métodos *Backward Differentiation Formula* [Ascher and Petzold, 1998].

Otra categorización con la que trabajaremos serán los métodos de un solo paso, y los métodos multipaso.

- **Métodos de un solo paso:** para obtener el siguiente valor con el que se tratará, el siguiente paso, sólo se utiliza información relativa al paso anterior. Es decir, como podemos ver en 2.2, para obtener y_{n+1} sólo

se utilizaría y_n . Entre estos podemos encontrarnos al método de Euler explícito, o a la familia de métodos de Runge-Kutta, que si bien tiene varias etapas, es de un solo paso.

- **Métodos multipaso:** usan varios valores anteriores de la solución para calcular el siguiente paso en el tiempo, en lugar de basarse solo en el valor actual. Es decir, que para obtener y_{n+1} se podrían utilizar pasos más antiguos como y_{n-1} o y_{n-2} . Para problemas de gran tamaño, los métodos multipaso permiten alcanzar resultados con gran precisión y de una forma más eficiente que los métodos de un paso.

2.3. Método de Euler

Como hemos comentado, el método de Euler es uno de los métodos numéricos más simples de los que disponemos para la resolución de EDOs. Se trata de un método explícito de un solo paso que se construye a partir de una sencilla idea geométrica: aproximar el valor de la solución en cada nodo por el valor que proporciona la **recta tangente a la solución** trazada desde el punto correspondiente al nodo anterior [Gallardo, 2018].




Figura 2.1: Aplicación del método de Euler [Calcs, 2023]

Emplearíamos la siguiente fórmula, aunque puede aparecer escrita de distintas formas equivalentes, aquí mostramos dos:

$$\begin{aligned} y_{n+1} &= y_n + \Delta t \cdot f(t_n, y_n) \\ y_{n+1} &= y_n + h \cdot f(x_n, y_n) \end{aligned} \tag{2.3}$$

Aplicando la misma al ejemplo de valor inicial que mencionamos antes, la ecuación 2.1, en la que se nos indicaba tanto $\frac{dy}{dt} = -2y$ como el valor inicial $y(0) = 1$, sabemos que y_n corresponde a la aproximación numérica de $y(t_n)$, y Δt (o h) representa la variación en el tiempo de un paso que estemos considerando. Además, en nuestro caso, $f(t_n, y_n)$ sería $-2 \cdot y_n$, y se nos da el valor inicial en t_0 . Por tanto, tomando estos valores, con un $\Delta t = 0.1$, y $t_f = 1.0$, calcularemos los sucesivos valores para $t = 0.1, 0.2, \dots, 1.0$.

El primer paso sería por tanto, partiendo de los valores iniciales, calcular el valor de y en $t = 0.1$, a saber:

$$y(t_1) = y(t_0 + \Delta t) = y_0 + \Delta t \cdot f(t_0, y_0) = 1 + 0.1 \cdot (-2 \cdot 1) = 0.8 \quad (2.4)$$

Si esto lo repitiéramos de forma sucesiva obtendríamos los siguientes resultados, los cuales además compararemos con el valor real $y(t) = e^{-2t}$ para obtener el error absoluto ε_a y el error relativo ε_r . Definiremos al error absoluto como la diferencia entre el valor real y nuestra aproximación, y al error relativo como el cociente entre el error absoluto y el valor real, en porcentaje.

Paso n	t_n	y_n (Euler)	y_n (Exacta)	ε_a	ε_r
0	0.0	Valor Inicial = 1.0		-	-
1	0.1	0.8	0.81873	0.01873	2.29
2	0.2	0.64	0.67032	0.03032	4.52
3	0.3	0.512	0.54881	0.03681	6.71
4	0.4	0.4096	0.44933	0.03973	8.84
5	0.5	0.32768	0.36788	0.04020	10.93
6	0.6	0.26214	0.30119	0.03905	12.97
7	0.7	0.20972	0.24660	0.03688	14.96
8	0.8	0.16777	0.20190	0.03412	16.90
9	0.9	0.13422	0.16530	0.03108	18.80
10	1.0	0.10737	0.13534	0.02796	20.66

Tabla 2.1: Comparativa entre la aproximación con Euler y valor real




Figura 2.2: Comparativa entre la aproximación con Euler y valor real

Como podemos observar en la tabla 2.1 y en la figura 2.2, los valores que obtenemos con el Euler explícito son próximos a los reales (eje Y izquierdo); el error absoluto se mantiene estable por debajo de 0.05, e incluso disminuye. Sin embargo, el error relativo (eje Y derecho) aumenta de forma lineal con cada iteración, y para la última alcanza un preocupante 20 %. Esto nos indica que para este problema, quizás el método numérico que hemos utilizado o el Δt que hemos considerado no son los más indicados.

2.4. Paralelización

Las dos tecnologías que vamos a utilizar para paralelizar nuestros algoritmos lo hacen desde prismas distintos, a saber, la primera permite establecer el paralelismo a nivel de CPUs multicore, **OpenMP** [Jin et al., 2024]; y la segunda lo hace a través de GPUs de la tecnológica NVIDIA, **CUDA** [Kirk and Hwu, 2010].

Por muy rápida que sea nuestra CPU, siempre llegaremos a un punto en que, bien por la complejidad de los problemas, bien por el tamaño que se maneje, una sola CPU con un código secuencial no va a ser suficiente. Es aquí donde entra el paralelismo, y es aquí donde nos centraremos.

La programación paralela es el conjunto de técnicas, modelos y arquitecturas que permiten ejecutar **múltiples operaciones de forma simultánea**, explotando el hardware moderno (CPU multicore, GPU masivamente paralelas, aceleradores, clústeres). Su objetivo es reducir el tiempo de ejecución, aumentar el rendimiento y permitir resolver problemas que, como hemos comentado, serían inviables usando un único procesador.

El paralelismo surge cuando un problema puede descomponerse en sub-tareas independientes que pueden ejecutarse al mismo tiempo. En términos formales, un programa es paralelizable si existe una partición de su espacio de trabajo en unidades que no presentan dependencias de datos que impidan su ejecución concurrente [Wilkinson and Allen, 2005]. Esto implica analizar dependencias de datos, localidad y acceso a memoria, granularidad de las tareas, y coste de sincronización.

Podríamos clasificar los distintos modelos de paralelismo que nos encontraremos en tres grandes grupos: [Grama et al., 2003]

- **Paralelismo de datos**, que consiste en aplicar la misma operación a múltiples elementos de un conjunto, a través de la vectorización, de bucles paralelos, o de operaciones *element-wise*. Este paralelismo se puede aprovechar con tecnologías como OpenMP, CUDA, OpenCL, o AVX, entre otros.
- **Paralelismo de tareas**, que consiste en ejecutar tareas heterogéneas en paralelo, como pipelines, árboles de tareas, o grafos de dependencias. Este modelo es usado por frameworks como TBB, Cilk, OpenMP tasks o CUDA graphs.
- **Paralelismo híbrido**, que combina ambos, buscando la explotación simultánea del paralelismo de tareas y el paralelismo de datos en una misma aplicación.

Algunos conceptos muy importantes que nos encontraremos son la concurrencia y el paralelismo. La **concurrencia** hace referencia a que varias tareas pueden ocurrir a la vez, o que ocurren simultáneamente de forma lógica. Una CPU mononúcleo puede cambiar rápidamente de una tarea a otra si no tienen dependencia entre ellas y son concurrentes. Mientras que el **paralelismo** se refiere a ejecutar físicamente varias tareas al mismo tiempo, por ejemplo a través de varios núcleos.

El **speedup** será la forma en la que mediremos las mejoras en la ejecución conforme aumenta el paralelismo. En nuestro caso, lo calcularemos a través del cociente del tiempo de ejecución del programa secuencial, entre el tiempo de ejecución de la versión paralela [Schryen, 2024]. Como todo código por bien optimizado que esté va a tener una parte secuencial que no pueda paralelizarse, buscaremos que el speedup aumente tanto como sea posible. Por ejemplo, pasando de un código secuencial a uno con 4 hebras OpenMP, el speedup ideal sería de 4, aunque entendemos que no será posible conseguirlo, pero sí acercarse lo suficiente dependiendo del problema y el algoritmo usado.

Otro concepto relacionado sería el de la **eficiencia**, que sería el cociente entre speedup y el número de cores empleado para obtener ese speedup. La eficiencia estará entre 0 y 1 (o entre 0 % y 100 %), y medirá cuánto se están aprovechando los recursos paralelos.

Al hilo de esto último, la **Ley de Amdahl** [Amdahl, 1967] nos indica que, con un tamaño de problema constante y aumentando el número de procesadores, la parte no paralelizable del algoritmo va a limitar nuestro speedup. Podemos ilustrarla tal que:

$$S(p) = \frac{1}{(1 - f) + f/p} \quad (2.5)$$

Siendo p el numero de procesadores, f la fracción paralelizable del programa, $1 - f$ por tanto sería la parte secuencial, y $S(p)$ sería el speedup máximo teórico. La interpretación que podemos hacer es que cuando aumentan los procesadores, la parte no paralelizable satura el speedup. Por ejemplo, con un 95 % del programa paralelizable, e infinitos procesadores, el speedup nunca superará 20.

Trayendo esto a un contexto más realista, lo que se nos indica es que, aunque obviamente aumentar los núcleos es efectivo, y reduciremos los tiempos de ejecución, llegará un número a partir del cual ya no merezca la pena, a no ser que reduzcamos la parte no paralelizable.




Figura 2.3: Representación gráfica de la Ley de Amdahl [Shiang et al., 2016]

También debemos mencionar la **Ley de Gustafson** [Gustafson, 1988], que parte de una premisa distinta, aumentar el tamaño del problema cuando tenemos más procesadores. A saber:

$$\begin{aligned}
S &= s + f \cdot n \\
S &= s + (1 - s) \cdot n \\
S &= n + (1 - n) \cdot s \\
S &= n - (n - 1) \cdot s \\
S &= (1 - f) + f \cdot n \\
S &= 1 + (n - 1) \cdot f
\end{aligned}
\tag{2.6}$$

Donde f es de nuevo la fracción paralelizable; s representa su fracción complementaria, la parte secuencial; n es el numero de procesadores; y S el *speedup*.

Aquí la interpretación que hacemos es que al aumentar el tamaño del problema, aumentamos la parte paralelizable, mientras que la secuencial se mantiene estable. Esto juega a nuestro favor, ya que trataremos grandes cantidades de datos.

La ley de Gustafson aporta un punto de vista más optimista al binomio procesadores-eficiencia, ya que nos dice que aunque la eficiencia no pueda ser perfecta, a medida que el problema y los procesadores crezcan, podrá acercarse mucho.




Figura 2.4: Representación gráfica de la Ley de Gustafson [Kostler et al., 2006]

Como podemos ver en la figura 2.4, sea cual sea el porcentaje paralelizable del algoritmo con el que se esté tratando, si aumenta el tamaño de este, y los núcleos tenemos en funcionamiento, aumentará el speedup; no hay cota superior.

Otro concepto importante será el de la **sincronización**. Cuando procesadores diferentes deban compartir algún dato entre ellos, o necesiten que haya terminado cierta tarea antes de empezar la siguiente, deberá haber una barrera en la que los hilos se esperen entre ellos. Estas barreras ralentizan mucho la ejecución y se deberá intentar reducirlas tanto como sea posible.

Para resolver los diferentes problemas hemos implementado tres métodos distintos, a saber: Runge-Kutta, que es explícito y utiliza pasos intermedios ($K1, K2$) para obtener los nuevos pasos; Adams-Bashforth, que también es explícito y multipaso, pero utiliza pasos antiguos (como f_{n-1} o f_{n-2}); y Adams-Bashforth-Moulton, un predictor-corrector multipaso basado en Adams-Moulton (formalmente implícito) que utiliza Adams-Bashforth para predecir y_{n+1} y sustituirlo en $f(t_{n+1}, y_{n+1})$.

2.5. Métodos de Runge-Kutta

Ahora que hemos tratado el método de Euler, podremos dar el siguiente paso hacia los métodos de **Runge-Kutta**. Aunque técnicamente ya lo hemos estado viendo, ya que los métodos de Runge-Kutta son generalizaciones de la fórmula básica de Euler [Segarra-Escandon, 2020]. Por esta razón, se dice que el método de Euler es un método de Runge-Kutta de primer orden.

En cada uno de los órdenes de la familia de métodos de Runge-Kutta resolveremos una serie de **etapas intermedias** para hallar el valor final. El método de orden 1, como hemos mencionado, coincidiría con Euler, como se puede ver en la ecuación 2.3.

Para ilustrar este punto, procedemos a pasar a la fórmula de segundo orden, en el que buscaremos encontrar constantes o parámetros w_1, w_2, α, β tal que la fórmula concuerda con un polinomio de Taylor de grado 2 [Zill, 2009].

$$\begin{aligned}y_{n+1} &= y_n + \Delta t \cdot (w_1 K_1 + w_2 K_2) \\K_1 &= f(t_n, y_n) \\K_2 &= f(t_n + \alpha \cdot \Delta t, y_n + \beta \cdot \Delta t \cdot K_1)\end{aligned}\tag{2.7}$$

Para el uso que haremos en este proyecto, basta decir que esto se puede hacer siempre que las constantes cumplan que:

$$\begin{aligned}w_1 + w_2 &= 1, \quad w_2 \alpha = \frac{1}{2} \text{ y } w_2 \beta = \frac{1}{2} \\w_1 &= 1 - w_2, \quad \alpha = \frac{2}{2w_2} \text{ y } \beta = \frac{1}{2w_2}\end{aligned}\tag{2.8}$$

Este es un sistema algebraico que posee tres ecuaciones y cuatro incógnitas, lo cual implica un número infinito de soluciones, donde $w_2 \neq 0$, y para nuestra aplicación práctica tomaremos $w_1 = w_2 = \frac{1}{2}$ y $\alpha = \beta = 1$, formando por tanto:

$$\begin{aligned}y_{n+1} &= y_n + \Delta t/2 \cdot (K_1 + K_2) \\K_1 &= f(t_n, y_n) \\K_2 &= f(t_n + \Delta t, y_n + K_1 \cdot \Delta t)\end{aligned}\tag{2.9}$$

De forma análoga, obtendremos el tercer orden:

$$\begin{aligned}y_{n+1} &= y_n + \Delta t/6 \cdot (K_1 + 4K_2 + K_3) \\K_1 &= f(t_n, y_n) \\K_2 &= f(t_n + \Delta t/2, y_n + K_1 \cdot \Delta t/2) \\K_3 &= f(t_n + \Delta t, y_n - K_1 \cdot \Delta t + 2K_2 \cdot \Delta t)\end{aligned}\tag{2.10}$$

Por último, en el método de Runge-Kutta de orden 4, también conocido como **método clásico de Runge-Kutta**, resolveremos diversos pasos que nos servirán para estimar de forma muy aproximada el resultado.




Figura 2.5: Demostración gráfica de RK4 [Nyandieka and Seger, 2023]

Será en éste en el que nos centraremos en los experimentos numéricos. Partiendo de una ecuación $dy/dt = f(t_n, y_n)$, un valor inicial $y(t_0) = y_0$, y de un tamaño de paso $\Delta t > 0$, **calcularemos iterativamente** los valores tal que:

$$\begin{aligned}
 y_{n+1} &= y_n + \Delta t/6 \cdot (K_1 + 2K_2 + 2K_3 + K_4) \\
 K_1 &= f(t_n, y_n) \\
 K_2 &= f(t_n + \Delta t/2, y_n + K_1 \cdot \Delta t/2) \\
 K_3 &= f(t_n + \Delta t/2, y_n + K_2 \cdot \Delta t/2) \\
 K_4 &= f(t_n + \Delta t, y_n + K_3 \cdot \Delta t)
 \end{aligned} \tag{2.11}$$

Aplicado en un contexto de programación, tendremos una clase **RungeKutta** con una función principal que aplicará el cálculo y algunas auxiliares que se explicarán más adelante. Dicha función principal tendrá el siguiente diseño, en el que se harán diversas llamadas a la evaluación de la derivada de cada problema en cuestión (aquí lo llamaremos **feval**):

Algoritmo 1 Runge-Kutta de Orden 4

```
 $y_n \leftarrow y_0$   
 $t_n \leftarrow t_0$   
while  $t_n < t_f$  do  
     $K1 \leftarrow feval(t_n, y_n)$   
     $K2 \leftarrow feval(t_n + \Delta t/2, y_n + K1 \cdot \Delta t/2)$   
     $K3 \leftarrow feval(t_n + \Delta t/2, y_n + K2 \cdot \Delta t/2)$   
     $K4 \leftarrow feval(t_n + \Delta t, y_n + K3 \cdot \Delta t)$   
     $y_n \leftarrow y_n + \Delta t/6 \cdot (K1 + 2 \cdot K2 + 2 \cdot K3 + K4)$   
     $t_n \leftarrow t_n + \Delta t$   
end while  
 $y_f \leftarrow y_n$ 
```

Como podemos ver, la aplicación del algoritmo es relativamente fácil de entender, se trabaja con 4 vectores auxiliares en los que hacemos los cálculos intermedios, que luego se suman ponderadamente. Como cada evaluación K depende de la anterior, no podremos hacer una operación vectorial en la que se evalúen los cuatro K en paralelo, sino que será en las otras operaciones, las evaluaciones de cada miembro, las sumas, y las multiplicaciones de cada vector, en las que podremos **explotar la concurrencia** para mejorar las prestaciones de nuestro código.

2.6. Métodos de Adams-Bashforth

A diferencia de Runge-Kutta, donde sólo considerábamos un valor y_n para obtener y_{n+1} , en la familia de métodos de **Adams-Bashforth**, al ser multipaso, sí tendremos en cuenta más puntos, como y_{n-1} o y_{n-3} , además de y_n . En este proyecto nos hemos centrado en los métodos de paso fijo, es decir, que la diferencia entre t_n y t_{n+1} es constante (e igual a Δt o h). Si bien existen otros métodos de paso variable, no serán tratados.

De forma general, tenemos que un método lineal de k pasos viene determinado por una expresión general tal que: [Molero et al., 2007]

$$\sum_{j=0}^k \alpha_j \cdot y_{n+j} = \Delta t \cdot \sum_{j=0}^k \beta_j \cdot f(t_{n+j}, y_{n+j}) , \quad n \geq 0 \quad (2.12)$$

Para poder aplicar esta fórmula necesitaremos un número determinado de **valores de arranque**, que serán iguales al valor de k . Como en los problemas de valor inicial sólo se proporciona el primero de ellos $y(y_n) = y_0$, los valores restantes deberemos conseguirlos aplicando otro método (que no sea multipaso), como por ejemplo, el método de Runge-Kutta clásico.

La expresión general de un método de Adams-Bashforth de k pasos es: [Molero et al., 2007]

$$y_{n+1} = y_n + \Delta t \cdot (\gamma_0 \cdot \nabla^0 + \gamma_1 \cdot \nabla^1 + \dots + \gamma_{k-1} \cdot \nabla^{k-1}) \cdot f(t_n, y_n)$$

donde

$$\gamma_i = \frac{1}{i! \cdot \Delta t^{i+1}} \int_{t_n}^{t_{n+1}} (t - t_n) \dots (t - t_{n-i+1}) \cdot dx \quad (2.13)$$

Aplicando la anterior ecuación 2.13, obtendríamos los distintos órdenes con los que trabajaremos. Al igual que con el método de Runge-Kutta, el método de Adams-Bashforth de orden 1 coincide con Euler explícito (ecuación 2.3). De igual manera obtendríamos:

- Adams-Bashforth de 2 pasos:

$$y_{n+1} = y_n + h/2 \cdot (3f_n - f_{n-1})$$

donde

$$f_n = f(t_n, y_n) \text{ y } f_{n-1} = f(t_{n-1}, y_{n-1}) \quad (2.14)$$

- Adams-Bashforth de orden 3:

$$y_{n+1} = y_n + h/12 \cdot (23f_n - 16f_{n-1} + 5f_{n-2}) \quad (2.15)$$

- Adams-Bashforth de orden 4:

$$y_{n+1} = y_n + h/24 \cdot (55f_n - 59f_{n-1} + 37f_{n-2} - 9f_{n-3}) \quad (2.16)$$

En el Adams Bashforth de orden 2, (ecuación 2.14) será el primer caso en el que vemos aplicada la teoría de los métodos multipaso, ya que, para obtener el paso y_2 , por ejemplo, deberíamos tener de antemano f_1 y f_0 , para los que a su vez necesitaríamos (a través del arranque con Runge-Kutta) y_1 y y_0 . Una vez hecho el arranque inicial para obtener y_2 , ya sí podríamos operar iterativamente sólo con Adams-Bashforth. Por otro lado, será con el método Adams-Bashforth de orden 4 (ecuación 2.16 con el que principalmente trabajaremos.

Llevándonos este método a la programación, tendremos una clase **AdamsBashforth** con una función **aplicar()** que se encargará de, primero, realizar un arranque con Runge-Kutta de orden 4 (algoritmo 1) y posteriormente poner en funcionamiento un bucle que evalúe la expresión (ecuaciones 2.3, 2.14, 2.15, o 2.16) tantas veces como esté establecido. En función del lenguaje utilizado y de la tecnología de paralelización, las operaciones vectoriales funcionarán de una forma u otra, pero el planteamiento será el mismo, con llamadas a la evaluación de cada problema en cuestión (**feval**).

A continuación tenemos el algoritmo para aplicar el método, en el cual k corresponde con el orden del mismo, por tanto y_k con el nuevo valor que se calcula en cada iteración, y los vectores $f_k, f_{k-1}, \dots, f_{n-k}$ son los resultados de aplicar `feval()` que se arrastran de iteraciones anteriores.

Algoritmo 2 Adams-Bashforth general de orden k

```

for  $i=1; i < k; ++i$  do
     $y_i \leftarrow \text{arranqueRK4}(y_{i-1})$ 
end for
for  $i=0; i < k; ++i$  do
     $f_i \leftarrow \text{feval}(f_i)$ 
end for
for  $t_n=t_0 + (k-1) \cdot \Delta t; t_n < t_f; t_n+=\Delta t$  do
     $y_k \leftarrow \text{AdamsBashforth}(k, y_{k-1}, f_n, f_{n-1}, \dots, f_{n-k})$ 
     $f_k \leftarrow \text{feval}(Y_k)$ 
     $\text{swap}(y_k, y_{k-1})$ 
    for  $i=1; i \leq k; ++i$  do
         $\text{swap}(f_n, f_{n-1})$ 
    end for
end for
 $Y_f \leftarrow Y_{k-1}$ 

```

La idea detrás del algoritmo es que, tras el arranque de los $k-1$ vectores, y la evaluación de los k vectores $f_n, f_{n-1}, \dots, f_{n-k}$, donde k es igual al orden de Adams-Bashforth que estemos aplicando, entrar en el bucle iterativo. En él, iteraremos sobre 2 vectores y_n , a saber, y_k y y_{k-1} , y sobre $k+1$ vectores f_n .

Una vez en el bucle, calculamos el nuevo valor de y_k , y con él, f_k . Posteriormente se hará un swap de vectores tal que y_k pasa a ser y_{k-1} , y todos los vectores f_n pasan a ser f_{n-1} . Así tendremos los datos preparados para la siguiente iteración.

2.7. Métodos de Adams-Bashforth-Moulton

Los métodos de Adams-Moulton tienen un funcionamiento similar a los de Adams-Bashforth, con la salvedad de que estos son implícitos. Esto quiere decir que para calcular y_{n+1} se hace uso de $f(t_{n+1}, y_{n+1})$. Para resolver este problema utilizaremos un sistema **Predictor-Corrector** que nos permite afrontar este método numérico como otro explícito más.

Un sistema predictor-corrector es una estrategia de integración numérica para resolver ecuaciones diferenciales ordinarias que combina dos métodos distintos: uno predictor, normalmente explícito, que genera una primera aproximación del valor futuro, y uno corrector, normalmente implícito,

que refina esa aproximación utilizando información adicional [Burden et al., 2016]. La idea central es aprovechar la rapidez de un método explícito y la estabilidad de un método implícito sin tener que resolver ecuaciones no lineales completas en cada paso.

En lugar de calcular directamente $y(t_{n+1}) = y_{n+1}$, el método predictor produce una estimación $(y_{n+1})^p$ basada únicamente en valores ya conocidos. Esa estimación se utiliza para evaluar la función $f(t_{n+1}, (y_{n+1})^p)$, que es la información que un método implícito necesitaría pero que normalmente obligaría a resolver una ecuación. Con esa evaluación, el corrector aplica una fórmula más precisa y obtiene un valor corregido.

Adams–Bashforth actúa como **predictor** porque es explícito y utiliza únicamente valores pasados de la derivada. Adams–Moulton actúa como **corrector** porque su fórmula implícita incorpora la derivada en el punto futuro, lo que mejora la precisión y la estabilidad. Al sustituir la derivada futura por la derivada evaluada en la predicción, el método no requiere resolver ecuaciones no lineales. El resultado es un método de orden alto, eficiente y con buena estabilidad, muy adecuado para problemas donde los métodos explícitos puros serían inestables o demasiado restrictivos en el tamaño del paso.

La expresión general de un método Adams-Moulton puro de k pasos es: [Molero et al., 2007]

$$y_{n+1} = y_n + \Delta t \cdot (\gamma_0 \cdot \nabla^0 + \gamma_1 \cdot \nabla^1 + \dots + \gamma_k \cdot \nabla^k) \cdot f(t_{n+1}, y_{n+1})$$

donde

$$\gamma_0 = 0 \text{ y } \gamma_i = \frac{1}{i! \cdot \Delta t^{i+1}} \int_{t_n}^{t_{n+1}} (t - t_{n+1}) \dots (t - t_{n-i+2}) dx \quad (2.17)$$

Y por tanto, las ecuaciones correspondientes a los mismos son las siguientes: [Segarra-Escandon, 2020]

■ **Adams-Moulton orden 0 (AM1)**

$$y_n = y_{n-1} + \Delta t \cdot f_n \quad (2.18)$$

■ **Adams-Moulton orden 1 (AM2)**

$$y_{n+1} = y_n + \Delta t/2 \cdot (f_{n+1} + f_n) \quad (2.19)$$

■ **Adams-Moulton orden 2 (AM3)**

$$y_{n+1} = y_n + \Delta t/12 \cdot (5f_{n+1} + 8f_n - f_{n-1}) \quad (2.20)$$

■ **Adams-Moulton orden 3 (AM4)**

$$y_{n+1} = y_n + \Delta t/24 \cdot (9f_{n+1} + 19f_n - 5f_{n-1} + f_{n-2}) \quad (2.21)$$

■ **Adams-Moulton orden 4 (AM5)**

$$y_{n+1} = y_n + \Delta t/720 \cdot (251f_{n+1} + 646f_n - 264f_{n-1} + 106f_{n-2} + 19f_{n-3}) \quad (2.22)$$

Es intuitivamente obvio que llegados a este punto no podríamos resolver estos métodos con las herramientas de las que disponemos. ¿Cómo llegamos a f_{n+1} sin disponer todavía de y_{n+1} ? Para resolver este problema, emplearemos un sistema Predictor-Corrector mediante el cual utilizamos Adams-Bashforth para hacer una primera aproximación de f_{n+1} , y la evaluamos para posteriormente hacer una segunda aproximación usando Adams-Moulton.

El **esquema general** será el siguiente, donde k es igual al orden, y_k es igual al nuevo valor que se calcula en cada iteración, los vectores $f_k, f_{k-1}, \dots, f_{n-k}$ son los resultados de aplicar **feval()** que se arrastran de iteraciones anteriores, y los vectores $y_{pred}, f_{pred}, y_{corr}$ y f_{corr} son vectores auxiliares para el cálculo de las etapas intermedias:

Algoritmo 3 Adams-Bashforth-Moulton de orden k

```

for  $i=1; i < k; ++i$  do
     $y_i \leftarrow \text{arranqueRK4}(y_{i-1})$ 
end for
for  $i=0; i < k; ++i$  do
     $f_i \leftarrow \text{feval}(y_i)$ 
end for
for  $t_n=t_0 + (k-1) \cdot \Delta t; t_n < t_f; t_n+=\Delta t$  do
     $y_{pred} \leftarrow \text{AdamsBashforth}(k, y_{k-1}, f_n, f_{n-1}, \dots, f_{n-k})$ 
     $f_{pred} \leftarrow \text{feval}(t_{n+h}, y_{pred})$ 
     $y_{corr} \leftarrow \text{AdamsMoulton}(k, y_{k-1}, f_{pred}, f_n, f_{n-1}, \dots, f_{n-k})$ 
     $f_{corr} \leftarrow \text{feval}(t_{n+h}, y_{corr})$ 
     $y_k \leftarrow \text{AdamsMoulton}(k, y_{k-1}, f_{corr}, f_n, f_{n-1}, \dots, f_{n-k})$ 
     $f_k \leftarrow \text{feval}(t_{n+h}, y_k)$ 
     $\text{swap}(y_k, y_{k-1})$ 
    for  $i=1; i \leq k; ++i$  do
         $\text{swap}(f_n, f_{n-1})$ 
    end for
end for
 $Y_f \leftarrow Y_{k-1}$ 

```

El funcionamiento del algoritmo acaba siendo muy similar al esquema de Adams-Bashforth, en tanto que hacemos el arranque con Runge-Kutta y posteriormente iteramos sobre los vectores Y_n y F_n . En este caso, añadimos además los vectores predictor y corrector, Y_{pred} y F_{corr} , que nos permiten aplicar la idea central de este método, manteniendo una buena eficiencia pero con resultados más precisos.

2.8. Problemas de prueba

MIRAR PAPER PROFE

Para poner en funcionamiento la implementación de estos métodos y de la paralelización de la que hablaremos a continuación, hemos tomado cuatro problemas distintos que nos permitan probar extensivamente ambas tecnologías, tanto OpenMP como CUDA. Los problemas en cuestión son:

SimpleAdvDiff y AdvDiff1D son problemas unidimensionales de advección - difusión en los que se trabajará con vectores que tendrán un número de EDOs igual al tamaño del vector y estarán formados por dos partes, una rígida (*stiff*) y una no rígida. Si bien servirán para establecer las bases del proyecto, nos centraremos más en los otros dos problemas.

Brusselator1D, el modelo brusselator es un tipo de modelo de reacción-difusión que fue desarrollado por la Brussels School. Este sistema está diseñado para analizar el comportamiento de sistemas químicos que presentan oscilación no lineal. [Mara'beh et al., 2024] Este problema tendrá 2 componentes, y por tanto el número de EDOs será el doble del tamaño que se elija.

Brusselator2D, este modelo es similar a su versión unidimensional, pero incorpora una componente extra reactiva. [Mara'beh et al., 2024] Además, está discretizado uniformemente en una malla de NxN puntos, por lo tanto, su número de EDOs será el doble del cuadrado del tamaño de problema.

2.9. OpenMP

OpenMP es una interfaz de programación paralela para **arquitecturas multiprocesador de memoria compartida**, diseñado para proporcionar una interfaz portable, escalable y de alto nivel que permita explotar el paralelismo en CPUs multinúcleo sin recurrir a APIs de hilos de bajo nivel. Su diseño se basa en directivas de compilador, rutinas de biblioteca y variables de entorno. Sigue el modelo de ejecución *fork-join*, donde un hilo maestro crea y sincroniza equipos de hilos que ejecutan regiones paralelas [Jin et al., 2024].




Figura 2.6: Modelo *fork-join* [Lawrence, 2019]

Surge en 1997, cuando Intel impulsa la creación del OpenMP Architecture Review Board (ARB), un consorcio formado por fabricantes de hardware y software (Intel, IBM, AMD, HP, Nvidia, Oracle, entre otros) con el objetivo de definir un estándar común para paralelismo en memoria compartida. La última versión de OpenMP, la 6.0, data de 2024.

OpenMP aprovecha el paralelismo mediante *multithreading*. El funcionamiento es relativamente simple, el programa comienza con un comportamiento secuencial y un hilo maestro. Cuando este hilo se encuentra una región paralela específica con `#pragma omp parallel`, se crea un equipo de hilos [ARB, 2024]. Los hilos ejecutan el bloque paralelo de forma concurrente, y al finalizar, los hilos se unen y el control vuelve al maestro.

Podemos identificar varios elementos principales, el primero de los cuales sería las directivas de compilador, como `#pragma omp parallel`, `#pragma omp for`, o `#pragma omp single`, y sus cláusulas como `schedule`, `shared`, o `default`. Otros elementos importantes son las funciones de biblioteca, como `omp_set_num_threads()` o `omp_get_wtime()`, y las variables de entorno, como `OMP_NUM_THREADS`, `OMP_SCHEDULE`, o `OMP_DYNAMIC`. [ARB, 2024]

Como hemos comentado, OpenMP opera sobre un modelo de memoria compartida en la que todos los hilos ven el mismo espacio de direcciones de memoria, en el que las variables pueden ser visibles por todos los hilos (*shared*), o cada hilo tiene su propia copia de una variable (*private*). Este modelo evita la necesidad de comunicación explícita entre procesos (como en MPI) [Jin et al., 2024], simplificando el desarrollo.

2.10. CUDA

CUDA, siglas de *Compute Unified Device Architecture* es una plataforma de computación paralela y un conjunto de APIs desarrollado por NVIDIA para ejecutar código general en sus GPUs. Incluye, entre otros, un modelo de programación a partir de C y C++; herramientas de compilación que generan código tanto para CPU como para GPU; un entorno de ejecución y una API para gestionar memoria, lanzamientos de kernels, streams; y librerías construidas sobre el propio modelo [Kirk and Hwu, 2010]. La idea principal es permitir que el programador trate a la GPU como un dispositivo de **cómputo masivamente paralelo**.

A modo de referencia, los primeros trabajos en los que se utiliza una GPU para cómputo general aparecen a principios de los 2000, en 2004 se crea internamente CUDA, y se lanza oficialmente en 2007. Desde entonces, la evolución de CUDA ha ido ligada a la evolución propia de las GPUs de NVIDIA, manteniendo el modelo de ejecución **SIMT** (*Single Instruction, Multiple Threads*) y añadiendo unidades especializadas como *Tensor Cores*, *Ray Tracing Cores*, o el mecanismo del *Transformer Engine* [NVIDIA, 2026].

CUDA implementa un modelo SIMT, en el cual el programador define una función denominada kernel que describe el código de un hilo, que se lanza desde la GPU y se ejecuta de forma concurrente en la GPU usando múltiples hilos. Los hilos se agrupan en bloques, que son arrays tridimensionales de hilos; y los bloques a su vez se agrupan como una grid, array tridimensional de bloques. Cada bloque se ejecuta en un *Streaming Multiprocessor*, dentro del cual los hilos se agrupan en **warps de 32 hilos** que se ejecutan físicamente en paralelo utilizando cores del multiprocesador. [Kirk and Hwu, 2010] El warp de hilos es, por tanto, la unidad de ejecución con la que trabajamos.

AÑADIR FIGURA DIAPOSITIVAS PROFESOR

Cuando se programa con CUDA se ha de tener en mente que se puede acceder a varias **memorias diferentes**, cada una con su propia latencia y ancho de banda, y entre ellas nos encontramos a los **registros**, que son la memoria de los hilos individuales, y la más rápida de todas; pasando por la **memoria compartida** (`__shared__`), que usan los bloques; la **memoria de constantes** (`__constant__`), que es de solo lectura, y va cacheada; y la **memoria global**, que se aloja en la VRAM de la GPU, que es la que se utiliza para almacenar grandes estructuras de datos. [Farber, 2011]




Figura 2.7: Jerarquía de memorias en CUDA [Beard, 2020]

El rendimiento de la memoria dependerá del buen hacer del programador, que será el encargado de buscar la coalescencia en los accesos a memoria global, del uso de para reutilizar datos, de que evite la divergencia de los warps, y de que se encargue de controlar los warps activos.

La **máxima coalescencia** ocurre cuando los 32 hilos de un warp acceden a direcciones de memoria que caen dentro del mínimo número de segmentos continuos necesarios para almacenar dichos datos [Kirk and Hwu, 2010]. Esto permite que la GPU atienda todos esos accesos el mínimo número de trabsacciones, lo cual implica la mayor eficiencia en el kernel al acceder a esos datos en memoria VRAM.

Por otro lado, la **divergencia de warps** ocurre cuando los hilos de un mismo warp toman caminos distintos en una rama condicional. Como el warp ejecuta las instrucciones en modo SIMT, si los hilos divergen, el hardware debe serializar las rutas [Farber, 2011]. Esto quiere decir que si los hilos se encuentran frente a un bloque if/else, lo que va a pasar es que el bloque if será ejecutado por los hilos que cumplan la condición, y el resto de hilos se quedarán en stand-by. A continuación, el resto de los hilos ejecutará el bloque else mientras los primeros se quedan esperando, y luego se combinarán los resultados.

Hay un matiz importante a tener en cuenta a la hora de describir la implementación CUDA, y es que lo que veremos a continuación serán funciones kernels, y no métodos de clase como vimos en el capítulo anterior. Una forma de verlo es que tendremos clases (como **Metodo**), y éstas tendrán sus funciones miembro que accederemos de forma normal con un objeto de la clase. Por otro lado tendremos las funciones kernel, que podrán ser llamados o no desde los métodos de las clases, y será donde ocurra el paralelismo de CUDA.

Aunque tengamos los kernel implementados en los archivos .cu de las clases, formalmente no son parte de ellas, son métodos globales que pueden ser llamados desde cualquier parte del código.

Como antes mencionamos, los kernel CUDA funcionan con **grids, bloques, y hebras**, y estos elementos interaccionan entre sí. Cuando llamamos a un kernel se crea una grid, que no es más que un conjunto de bloques con un tamaño predeterminado. Esta grid podrá tener una, dos, o tres dimensiones, y en cualquiera de los casos contendrá un número determinado de bloques. Estos bloques a su vez también tendrán de una a tres dimensiones y contendrán a las hebras, que serán con las que nosotros trabajaremos, indicando a cada hebra qué hacer dentro del kernel.

Aquí podemos ver un ejemplo ilustrativo en el que un kernel particular es llamado y crea una grid bidimensional de bloques, y a su vez los bloques por dentro son tridimensionales.




Figura 2.8: Grids y bloques CUDA [Casas, 2024]

Como primer ejemplo para ilustrar el modelo, podemos tomar una función auxiliar de la clase `Metodo` como la que ya vimos implementada en OpenMP (algoritmo 6), y transformarla al paradigma de programación de CUDA.

Algoritmo 4 Kernel de vectorCopia

```

 $i \leftarrow \text{blockDim.x} \cdot \text{blockIdx.x} + \text{threadIdx.x}$ 
if  $i < N$  then
     $Y[i] \leftarrow X[i]$ 
end if

```

Por un lado, como podemos ver en la primera línea, se calcula un valor i que es igual a una multiplicación y una suma. Identificando a esos 3 elementos tenemos primero a `blockDim.x`, que es un valor igual al tamaño de la dimensión X del bloque al que pertenezca cada thread particular. Luego, `blockIdx.x` designa al bloque individual que contenga cada thread que ejecute el kernel, y de igual manera `threadIdx.x` será el identificador individual de cada thread dentro de su bloque. Combinando los 3 generamos un identificador único para cada uno de los threads que genere el todo el grid.

Por otro lado, se hace la comprobación de que el identificador del thread es menor que el tamaño de los vectores para evitar posibles accesos erróneos a memoria. Esto ha de hacerse ya que, si tenemos un tamaño de problema

N, se generará un grid con tantos bloques de tamaño `blockDim.x` como para que el total de hebras sea siempre mayor o igual a N. Dicho de otra forma, con un tamaño de bloque de 256, y un tamaño de problema de 1000, se generaría una grid con 4 bloques (y por tanto 1024 hebras), y las últimas 24 no trabajarían.

Capítulo 3

Implementación Multihebra

Este capítulo aborda el proceso de llevar los métodos numéricos de los que se ha hablado previamente (véase los algoritmos 1, 2, o 3) a un entorno multihebra como es OpenMP. Comienza estableciendo una base secuencial, tanto para los problemas como para los métodos de resolución. A partir de esta maqueta funcional, se introduce la necesidad de paralelizar el cálculo, destacando que el bucle principal de integración no puede dividirse directamente debido a su dependencia secuencial, lo que obliga a buscar estrategias alternativas de descomposición del trabajo.

A continuación, el capítulo presenta y desarrolla dos enfoques distintos de paralelización: el paralelismo por operaciones y el paralelismo por componentes. El primero distribuye el trabajo dentro de cada operación vectorial, y el segundo concentra todo el trabajo dentro de una única región paralela.

Finalmente, el capítulo analiza de forma detallada los resultados experimentales obtenidos con ambas estrategias, aplicadas a distintos métodos numéricos y problemas de diversa complejidad. Se estudian tiempos de ejecución, speedup y eficiencia, y se interpretan los resultados.

3.1. Implementación Secuencial

Tomaremos como punto de partida la implementación secuencial de los PVIIs [Mantas, 2024], de la cual ya disponemos.




Figura 3.1: Diagrama de Clases de los problemas en la implementación usando OpenMP

Como comentamos anteriormente, no nos centraremos en la resolución de los problemas *per se*, puesto que ésta se nos da ya hecha y corregida, sino que nuestros esfuerzos se centrarán en implementar los métodos de resolución en ambas plataformas paralelas, y buscar la **máxima eficiencia**. Para facilitar la implementación y la cohesión del código, definimos una clase abstracta **Problema** de la cual heredarán los cuatro problemas.

El siguiente paso, por tanto, será realizar una implementación secuencial de los métodos, partiendo de los algoritmos que previamente hemos comentado, Runge-Kutta, Adams-Bashforth, y Adamd-Bashforth-Moulton, a saber, algoritmos 1, 2, y 3, respectivamente. El lenguaje elegido será C++, para luego poder añadir la parte de OpenMP o CUDA.

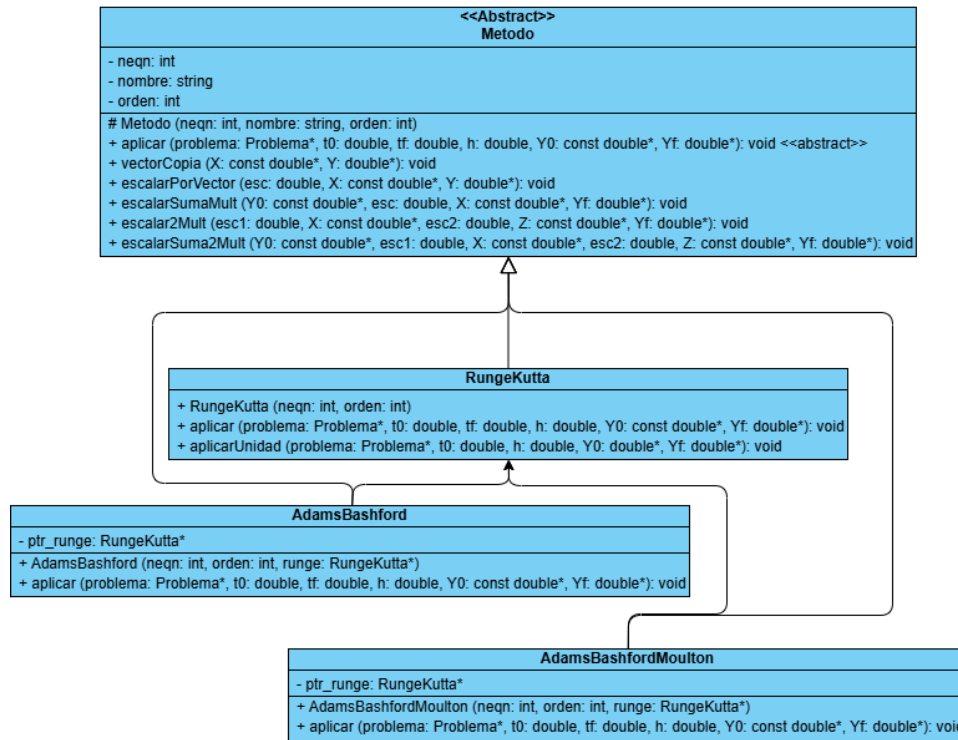


Figura 3.2: Diagrama de Clases de los métodos de resolución en la implementación usando OpenMP

El planteamiento que se hace con los métodos de resolución es similar al de los problemas, una clase abstracta padre de la cual puedan heredar los métodos. Además, en la clase padre **Metodo** hemos implementado diversas funciones auxiliares que nos van a facilitar el trabajo con vectores. Con este diseño, a través de la **herencia** y el **polimorfismo**, podríamos aumentar el alcance de nuestro proyecto añadiendo nuevos métodos o diferentes problemas sin dificultad ninguna.

Ahora que tenemos una primera maqueta funcional (aunque poco eficiente), podremos comenzar con el trabajo de paralelización. De cara a nuestro proyecto, lo primero que debemos tener en cuenta es que no podemos simplemente paralelizar el bucle principal con el que trabajamos (e.g. el bucle **while** en el algoritmo 2) porque cada iteración necesita de la anterior para calcular el siguiente paso. Debemos buscar por tanto otras formas de descomponer el cálculo. En el caso de OpenMP, hemos planteado dos enfoques en particular, **paralelismo por operaciones**, y **por componentes**.

3.2. Paralelismo por Operaciones

En esta estrategia buscamos que cada función paralelice su propio trabajo. Eso quiere decir que cada operación vectorial, como la evaluación de la derivada (`feval`), o el producto escalar-vector, tiene su propio `#pragma omp parallel`. Por tanto, crea un equipo de hilos, reparte el trabajo, y lo sincroniza.

De forma simplificada, veamos un ejemplo de la implementación de Adams-Bashforth 4 (AB4), ecuación 2.16:

Algoritmo 5 Implementación de AB4 con Paralelismo por Operaciones

```

 $Y_{n0} \leftarrow Y_0$ 
for  $i=1; i < 4; ++i$  do
     $Y_i \leftarrow \text{arranqueRK4}(Y_{i-1})$ 
end for
for  $i=0; i < 4; ++i$  do
     $f_i \leftarrow \text{feval}(t_0 + i\Delta t, y_i)$ 
end for
for  $t_n=t_0+3\Delta t; t_n < t_f; t_n+=\Delta t$  do
     $y_4 \leftarrow \text{funcionesAuxiliares}(t_n, y_3, f_0, f_1, f_2, f_3)$ 
     $f_4 \leftarrow \text{feval}(t_n + \Delta t, y_4)$ 
     $\text{swap}(y_{n4}, y_{n3})$ 
    for  $i=1; i \leq 4; ++i$  do
         $\text{swap}(f_n, f_{n-1})$ 
    end for
end for
 $Y_f \leftarrow Y_{n3}$ 

```

Cada implementación de algoritmos siguiendo este paradigma de paralelismo por operaciones intentará **dividir el trabajo** en varias funciones auxiliares (utilizando las que aporta la clase abstracta `Metodo`). Dentro de cada una de ellas se creará el grupo de hilos, se repartirá el trabajo (cada hilo tendrá un "trozo" de vector sobre el que trabajar), y una vez finalicen se sincronizará para retornar a la función principal.

Por ejemplo, `vectorCopia()`:

Algoritmo 6 Implementación de Función Auxiliar `vectorCopia`

```

#pragma omp parallel for schedule(static)
for  $i=0; i < neqn; ++i$  do
     $Y[i] \leftarrow X[i]$ 
end for

```

Esta estrategia trae consigo ventajas como la **modularidad**, ya que

cada operación vectorial es independiente y autocontenida, lo cual facilita la depuración y la legibilidad del código.

El principal punto negativo de esta estrategia es que trae consigo un *overhead* alto, ya que cada función tiene una barrera implícita al acabar un `parallel for`, en cada iteración del bucle hay varias llamadas a funciones, y el bucle itera un elevado número de veces. Esto equivale a más paradas de las que serían deseadas, además de que los hilos entran y salen de regiones paralelas constantemente.

3.3. Paralelismo por Componentes

Frente al paralelismo de operaciones, tenemos el paralelismo por componentes (o por elementos), en el que sólo tenemos una gran región *parallel* dentro de la cual ocurre todo el procesamiento paralelo, y cada hebra calcula su parte del procesamiento de los vectores.

Esto quiere decir que se creará un **único equipo de hilos** al entrar en el `parallel`, y todos los hilos permanecerán activos e iterarán en el bucle, paso a paso. Dentro del bucle iterativo, habrá diversos `#pragma omp for` que repartirán los índices entre los hilos. Esto además nos permitirá reducir las **barreras de sincronización**. Para poder comparar con la anterior implementación 5, describimos el mismo algoritmo (2.16) pero usando esta estrategia:

Algoritmo 7 Implementación de AB4 con Paralelismo por Componentes

```
Yn0 ← Y0
for j=1; j < 3; ++j do
    yj ← arranqueRK4(yj-1)
end for
for j=0; j < 3; ++j do
    fj ← feval(t0 + jΔt, yj)
end for
#pragma omp parallel
for tn=t0+3Δt; tn < tf; tn+=Δt do
    #pragma omp for schedule(static)
    for i=0; i < neqn; ++i do
        y4[i] = y3[i] + Δt/24 * (55f3[i] - 59f2[i] + 37f1[i] - 9f0[i])
    end for
    #pragma omp for schedule(static)
    for i=0; i < neqn; ++i do
        f4[i] ← feval.i(tn + Δt, y4, i)
    end for
    #pragma omp single
    swap(Yn4, Yn3)
    for j=1; j ≤ 4; ++j do
        swap(fj, fj-1)
    end for
end for
Yf ← Yn3
```

La idea principal detrás de esta estrategia es **reducir el *overhead*** provocado por tener demasiadas barreras de sincronización, y mejorar el uso de la caché. Para mejorar la implementación hacemos uso de directivas como `schedule (static)`, con la que indicamos cómo deben repartirse las iteraciones entre los hilos. En este caso, se divide el rango de iteraciones en bloques contiguos y de tamaño fijo, y se asigna cada bloque a un hilo antes de empezar la ejecución del bucle. Esto es práctico cuando sabemos de antemano que todas las iteraciones van a costar lo mismos.

Algunas de las desventajas que tendremos es que el código es más complejo, pues no se pueden reutilizar funciones como el `feval()` secuencial (que sí lo aprovechábamos en el paralelismo por operaciones), sino que hay que hacer una versión específica para los componentes. De igual manera, no se pueden utilizar las funciones auxiliares, porque están diseñadas para tratar los vectores completos, no **elementos individuales**.

3.4. Resultados experimentales

Todas las mediciones aquí presentes se han realizado teniendo como factores comunes $t_0 = 0.0$, $t_f = 1.0$, y $\Delta t = 10^{-6}$. Y se han tomado en una plataforma de cómputo de la Universidad de Granada con las siguientes características:

- CPU: Intel(R) Xeon(R) Silver 4214R CPU @ 2.40GHz
- Familia CPU: 6
- Modelo: 85
- Hilos por core: 2
- Cores por socket: 12
- Sockets: 2
- Caché:
 - L1d: 768 KiB
 - L1i: 768 KiB
 - L2: 24 MiB
 - L3: 33 MiB
- GPU: NVIDIA GeForce RTX 2080 Ti
- RAM: 62 GiB de RAM física
- Memoria de intercambio (Swap Memory): 2.0 GiB
- Versión de OpenMP: 4.5
- Versión de CUDA: 12.6
- Versión de g++: 12.3.0

Ante la pregunta sobre qué estrategia de paralelización es mejor, la respuesta sería, como casi siempre en informática, que depende.

En un primer planteamiento, parece que el paralelismo por componentes debería ser mejor. Reduce la creación y destrucción repetitiva de las hebras, y reduce las barreras de sincronización.

Un matiz importante que debemos hacer es que, aunque hablemos de creación y destrucción de hilos iterativa, no siempre ha de ocurrir así. Es cierto que, de forma lógica, el modelo *fork-join* de OpenMP describe de esa forma el comportamiento de los hilos; se crean, se usan, se destruyen. [Jin et al., 2024] Sin embargo, esto no siempre ocurre así (ya que sería muy costoso).

Existe un concepto llamado *thread pooling* [Barlas, 2023], que describe que el entorno de ejecución podrá **devolver los hilos** a la *pool* en lugar de destruirlos, y así ahorrarse crearlos posteriormente. Esto eliminaría la principal desventaja del paralelismo por operaciones.

De forma análoga, el *runtime system* [Chapman et al., 2007] no siempre mantiene los **hilos activos** (como pudiera parecer), aunque no haya finalizado el bloque `parallel`, ya que si el trabajo dentro de cada bloque `omp for` es pequeño, el compilador puede decidir dormir los hilos para ahorrar energía. Esto puede provocar pérdida de tiempo al tener que despertar los hilos, y latencias de sincronización más altas.

Otro dato a tener en cuenta, es que en el planteamiento de nuestros problemas, las llamadas a `feval_i()` son muy baratas, y el trabajo por iteración es pequeño, mientras que `feval()` es más pesado, y en cierta forma se amortiza el *overhead* al hacerse una única llamada en lugar de *neqn* llamadas.

Podemos comenzar, por ejemplo, comparando los tiempos al resolver los problemas `SimpleAdvDiff` y `Brusselator1D` con 100.000 ecuaciones.

Solver	Hebras	Estrategia	T(adv)	T(br)
Runge-Kutta	1	OMP Componentes	1568.93	2501.84
		OMP Operaciones	345.558	1544.87
	4	OMP Componentes	432.421	670.504
		OMP Operaciones	98.1909	371.93
	16	OMP Componentes	134.355	197.065
		OMP Operaciones	78.5254	180.327
Adams-Bashforth	1	OMP Componentes	294.639	707.634
		OMP Operaciones	175.832	556.051
	4	OMP Componentes	72.22	179.559
		OMP Operaciones	40.6982	130.993
	16	OMP Componentes	34.5692	56.5174
		OMP Operaciones	39.7005	66.1485
Adams-Bashforth-Moulton	1	OMP Componentes	1367.14	2914.04
		OMP Operaciones	561.564	1772.73
	4	OMP Componentes	359.767	785.555
		OMP Operaciones	138.931	438.018
	16	OMP Componentes	150.579	237.236
		OMP Operaciones	139.524	219.918

Tabla 3.1: Mediciones experimentales de `SimpleAdvDiff` y `Brusselator1D` con 100000 ecuaciones




Figura 3.3: Brusselator1D 100.000 ecuaciones




Figura 3.4: SimpleAdv 100.000 ecuaciones

Como podemos ver, hay una mejora sustancial del tiempo al pasar de 1 a 4 y a 16 hebras, con ambas estrategias de paralelismo, y con los 3 métodos numéricos. Además, se aprecia que la resolución con Adams-Bashforth es más rápida que Runge-Kutta, ya que es más directa y no requiere de los etapas intermedias (K1, K2, K3, K4), y también es mucho más veloz que el predictor-corrector Adams-Bashforth-Moulton, ya que éste último llama a Adams-Bashforth dentro de su bucle de ejecución. Cabe matizar que la comparación únicamente de sus velocidades no es justa, y que si se quisiera hacer una evaluación mas rigurosa de un método frente a otro, debería tenerse en cuenta también el error, y usar un paso variable.

Además, podemos ver que para este tipo y tamaño de problema, el pa-

ralelismo por operaciones es más eficiente para 4 hebras, pero ambos se equiparan cuando se alcanzan las 16.

Podemos probar por ejemplo, con el problema más complejo (*Brusselator2D*), y el método que más tarda (*ABM4*), y podemos comparar la evolución del tiempo conforme aumenta el tamaño del problema, a saber, con un número de ecuaciones igual a 45000, 80000 y 125000.

neqn	Hebras	Estrategia	T (s)	Speedup	Eficiencia
45000	1	Operaciones	976.061	1	100
		Componentes	2151.79		
	4	Operaciones	263.081	3.710115896	92.7528974
		Componentes	569.693	3.777104511	94.4276128
	16	Operaciones	180.662	5.402691213	33.7668201
		Componentes	206.744	10.40799249	65.0499531
80000	1	Operaciones	1825.86	1	100
		Componentes	3970.37		
	4	Operaciones	466.282	3.915784868	97.8946217
		Componentes	1049.35	3.78364702	94.5911755
	16	Operaciones	214.67	8.505426934	53.1589183
		Componentes	331.809	11.96582974	74.7864359
125000	1	Operaciones	2692.79	1	100
		Componentes	5982.94		
	4	Operaciones	675.123	3.988591708	99.7147927
		Componentes	1593.61	3.754331361	93.8582840
	16	Operaciones	264.402	10.18445398	63.6528373
		Componentes	445.081	13.44236218	84.0147636

Tabla 3.2: Brusselator2D con ABM4

Para calcular el speedup y la eficiencia, hemos comparado los valores de mismo tamaño de problema y estrategia, para que la comparación sea más justa. Más allá de lo obvio, que conforme aumenta el tamaño del problema, aumentan los tiempos, es cuanto menos destacable la variación en los speedups que se alcanzan en función del aumento de las hebras, en una estrategia y otra.




Figura 3.5: ABM4 resolviendo Brusselator2D

Partiendo de los mismos datos, pero tomando ahora solo el speedup y la eficiencia, y quedándonos con paralelismo de operaciones, tendríamos estas métricas:




Figura 3.6: Speedup y Eficiencia - ABM4 Brusselator2D

Tenemos la barras del speedup en azul y alineadas con el eje Y izquierdo, y en naranja y con el eje Y derecho la eficiencia en valores porcentuales. Obviamente, para 1 hebra siempre tendremos un speedup de 1, y una eficiencia de 100 %.

Más allá de eso, podemos ver varias ideas en juego a la vez. Si nos centramos en cualquiera de los 3 tamaños, podemos ver el efecto de la Ley de Amdahl [Amdahl, 1967]; con un mismo tamaño de problema, conforme crece el número de hilos, aumenta el speedup pero disminuye la eficiencia,

ya que siempre queda una parte secuencial que no se puede paralelizar.

Análogo a esto, si nos fijamos ahora en las columnas de la eficiencia, podemos ver que, para un mismo número de hebras, conforme aumenta el tamaño de problema, la eficiencia lo hace con él, pasando de un 33 %, a un 53 %, y a un 63 %, cuando observamos los datos relativos a las 16 hebras por ejemplo. Esto coincide con lo previsto según la ley de Gustafson [Gustafson, 1988], ya que al aumentar el tamaño del problema, crece la parte del programa que es paralelizable, y por lo tanto la eficiencia aumenta también.

Capítulo 4

Implementación para GPU

Este capítulo se centra en trasladar la resolución numérica de los problemas a través de los métodos numéricos (véase los algoritmos 1, 2, o 3) a una implementación para GPU mediante CUDA, adaptando la estructura previamente utilizada en OpenMP a las particularidades del procesamiento masivamente paralelo. Para ello se reorganizan las clases de los problemas y de los métodos, introduciendo elementos propios de CUDA, como el uso de memoria constante. Esta adaptación implica rediseñar ciertas funciones para que los kernels dispongan de todo lo necesario para poder lanzarse.

A continuación, el capítulo describe la implementación de los kernels asociados a cada problema y método numérico. Se explica también cómo las funciones auxiliares de la versión CPU se transforman en kernels equivalentes, y cómo la estructura de clases se amplía para soportar nuevas variantes de ejecución, como las versiones basadas en CUDA Graphs. Éstas permiten capturar y reutilizar secuencias de operaciones.

Finalmente, el capítulo explora dos optimizaciones adicionales: el uso de warp shuffle para reducir accesos a memoria global y la reorganización de los datos mediante grids multidimensionales. Ambas técnicas buscan mejorar la eficiencia del acceso a memoria y la comunicación entre hilos dentro de un warp. El capítulo concluye mostrando comparativas detalladas entre las distintas variantes, la implementación multihebra y la secuencial, y analizando los resultados y las ganancias obtenidas.

4.1. Implementación

Comenzaremos implementando los problemas de prueba (véase sección 2.8). La estructura que tendremos será similar a la implementación de OpenMP (véase figura 3.1) con un par de cambios que nacen de la naturaleza de las peculiaridades propias del **procesamiento en GPUs**. En todas las clases, además de las variables relativas al tamaño del problema (**neqn** y **nx**), también deberemos controlar las variables **grid** y **block**, que serán necesarias

para el kernel, ya que indican las dimensiones tanto de la grid de bloques, como de los bloques de hebras usados.




Figura 4.1: Diagrama de Clases CUDA para los problemas

Además, la función `feval()` sólo actuará como una envoltura desde la que se llama al kernel que evalúa realmente la función derivada. Usamos este sistema porque, como mencionamos, los kernels no son funciones miembro y no pueden acceder a los atributos de las clases, así que la función `feval()` actúa de intermediaria entre los métodos de clase y los kernels de los problemas. Además, se ha eliminado cualquier función auxiliar que se llame internamente desde `feval()`, ya que los kernel no pueden llamar a funciones que sean parte del host, métodos virtuales, o funciones miembro que utilicen a la CPU.

Algoritmo 8 Implementación de `feval` CUDA

```
kernel_problema<<<grid,block>>>(t, Y, DY);
```

A través de la herencia, las clases método podrán llamar a la función miembro `feval()` de las clases problema, y que sea cada problema el que llame a su kernel correspondiente, con la configuración de grids y bloques correcta para su ejecución en la GPU.

Hay otra función que no teníamos en las implementaciones de OpenMP y es `updateConstants()`. El planteamiento es simple, tenemos el inconveniente de que los kernels no pueden acceder a métodos miembro de los objetos problema, como a los *getters*, y por tanto `feval()` debería pasar como argumento al kernel todas las variables del problema que necesite (como nx).

Esto no sería una solución ideal porque, aunque no afectaría al rendimiento de la ejecución, sí lo haría a la eficiencia del lanzamiento del kernel. Esto se daría porque cada vez que se lanza un kernel los argumentos del mismo han de ser empaquetados por el *runtime* y copiados a un área de parámetros. En nuestro caso además los kernel `feval()` se lanzan muchas veces, aumentando el impacto.

La solución que proponemos a este contratiempo es utilizar la **memoria de constantes** [Farber, 2011]. En cada header `.h` de los problemas se implementa una estructura que contendrá los parámetros que utilizará el kernel asociado a ese problema.




Figura 4.2: Diagrama de Clases de los structs constantes

Posteriormente en el archivo *source* `.cu` se declara un objeto de esa estructura.

Algoritmo 9 Declaración del struct constante

```
extern __constant__ Params_br1d cte_br1d;
```

Más tarde, los métodos de resolución numérica desde su método *aplicar()* podrán llamar a esta función miembro de la clase problema, y ella se encargará de actualizar los valores y de transferirlos a memoria constante para que pueda ser utilizada por el kernel con una gran eficiencia. El algoritmo 10 muestra como se haría para la clase Brusselator1D.

Algoritmo 10 Función `updateConstants()` de `Brusselator1D`

```
Crear objeto aux de tipo Params_br1d  
aux.neqn  $\leftarrow$  get_neqn()  
aux.nx  $\leftarrow$  get_nx()  
aux.A  $\leftarrow$  get_A()  
aux.B  $\leftarrow$  get_B()  
aux.DD  $\leftarrow$  get_DD()  
cudaMemcpyToSymbol(cte_br1d, &aux, sizeof(Params_br1d))
```

Ahora que tenemos todas las partes que nos faltaban, podemos pasar a los kernels. En el planteamiento que hemos hecho de las clases, cada clase **problema** tendrá un único kernel encargado de hacer las transformaciones necesarias (como hacía **feval** en OpenMP). Veamos la versión resumida del pseudocódigo de uno de estos kernels:

Algoritmo 11 Kernel `feval` de `AdvDiff1D`

```
thread  $\leftarrow$  blockDim.x  $\cdot$  blockIdx.x + threadIdx.x  
ult  $\leftarrow$  neqn - 1  
if thread < neqn then  $\triangleright$  Check de hebras  
    i_ant  $\leftarrow$  (thread == 0) ? ult : (thread - 1)  $\triangleright$  Vecinos y frontera  
    i_pst  $\leftarrow$  (thread == ult) ? 0 : (thread + 1)  
    val_ant  $\leftarrow$  Y[i_ant]  $\triangleright$  Obtenemos valores  
    valor  $\leftarrow$  Y[thread]  
    val_pst  $\leftarrow$  Y[i_pst]  
    DY[thread]  $\leftarrow$  Cálculo usando val_ant, valor, val_pst, thread, t...  
end if
```

En el ejemplo, podemos diferenciar varias partes. Primero declaramos algunos valores que se usarán más adelante, como el número de hilo único de cada thread(**thread**), o el identificador del último hilo válido(**ult**). Posteriormente, tras la comprobación de que sólo ejecuten tantos hilos como elementos del vector, obtenemos los identificadores de los vecinos(**i_ant** y **i_pst**). Se usan operadores ternarios para corregir los casos frontera en los que el índice vecino se salga del rango.

Finalmente, ahora que disponemos de los identificadores, obtenemos, del vector alojado en memoria global, el valor que corresponde tanto al hilo en cuestión como a los vecinos. Y una vez que se tienen todos estos valores se procede al cálculo del nuevo valor, y asigna al vector salida, **DY[thread]**. Como hemos mencionado, todos los hilos del kernel lo ejecutarán concurrentemente.

De forma análoga a la implementación de los problemas, hay varios cambios que deben ser mencionados. Seguimos teniendo una clase abstracta padre **Metodo** que sirve de template a las hijas. En esta implementación, las

funciones auxiliares que tenía la clase son ahora kernels con la misma funcionalidad, como podemos ver en el algoritmo 4.

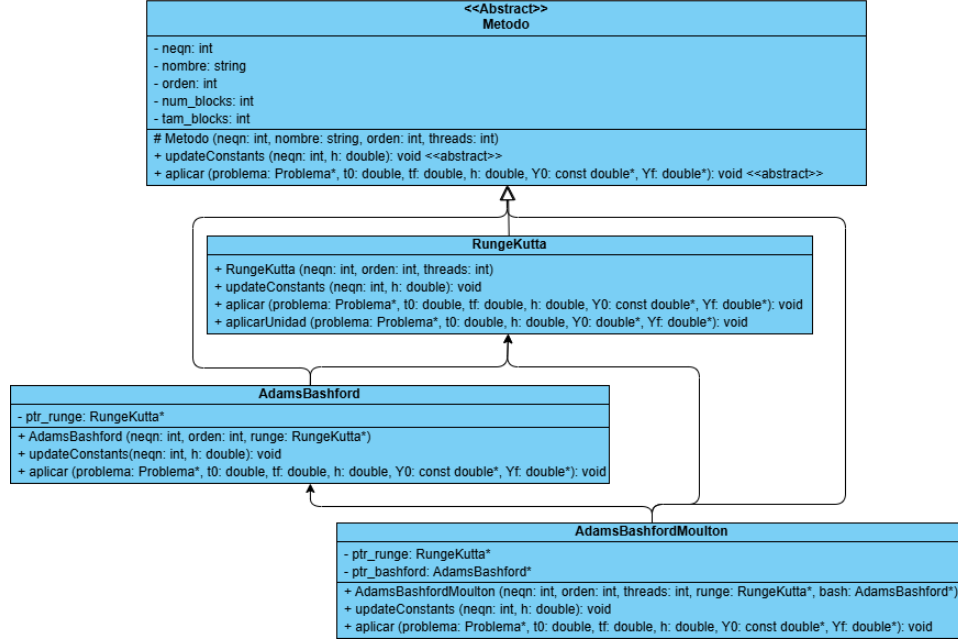


Figura 4.3: Diagrama de Clases de los Métodos en la versión CUDA

De igual manera, tanto la clase padre como las tres hijas tienen un *struct* asociado, alojado en memoria de constantes, y un método propio `updateConstants()` encargado de actualizar ese *struct* de constantes antes de hacer uso de sus kernels.

Pasamos ahora al método `aplicar()`, la implementación en los 3 métodos es similar, cambiando sólo los pasos que se siguen para pasar de Y_n a Y_{n+1} . Veamos por ejemplo, cómo sería el pseudocódigo de Runge-Kutta de orden 2.

Algoritmo 12 Aplicar para el método Runge-Kutta de orden 2 en CUDA

```

problema->updateConstants(neqn, h)           ▷ Memoria constante
 $Y_n \leftarrow Y_0$ 
for  $t_n=t_0; t_n < t_f; t_n+=\Delta t$  do
     $K1 \leftarrow feval(t_n; y_n)$ 
     $y_{aux} \leftarrow kernel\_escalarSumaMult(y_n, \Delta t, K1)$            ▷ Kernel auxiliar
     $K2 \leftarrow feval(t_n; y_{aux})$ 
     $y_n \leftarrow kernel\_sumatoriaRK2(K1, K2)$            ▷ Kernel principal RK2
end for
 $y_f \leftarrow y_n$ 
  
```

Cabe destacar que las funciones `aplicar()` siempre incluyen las 4 órdenes mencionadas, aunque por facilidad de comprensión del pseudocódigo sólo se ilustra aquí una de las órdenes. Además, los kernels nunca devuelven ningún dato, todo debe pasárseles como atributo.

Debido a la naturaleza de estos métodos numéricos, que utilizan los valores presentes para predecir los futuros, no podemos evitar el bucle `for` con el que se itera, y sólo podemos trabajar la paralelización dentro de él, sabiendo que el vector con el que acaba una iteración será aquel con el que empieza la siguiente.

4.2. Resultados Experimentales

Todas las mediciones aquí presentes se han realizado teniendo como factores comunes $t_0 = 0.0$, $t_f = 1.0$, $\Delta t = 10^{-6}$, y tamaño de *block* de 256 hebras. Y se han tomado en una plataforma de cómputo de la Universidad de Granada con las siguientes características:

- CPU: Intel(R) Xeon(R) Silver 4214R CPU @ 2.40GHz
- Familia CPU: 6
- Modelo: 85
- Hilos por core: 2
- Cores por socket: 12
- Sockets: 2
- Caché:
 - L1d: 768 KiB
 - L1i: 768 KiB
 - L2: 24 MiB
 - L3: 33 MiB
- GPU: NVIDIA GeForce RTX 2080 Ti
- RAM: 62 GiB de RAM física
- Memoria de intercambio (Swap Memory): 2.0 GiB
- Versión de OpenMP: 4.5
- Versión de CUDA: 12.6
- Versión de g++: 12.3.0

Comenzaremos midiendo los tiempos de los 3 métodos de resolución frente al problema Brusselator2D con 125.000 ecuaciones, y comparando los resultados entre la ejecución secuencial, OpenMP con 16 hebras, y CUDA con un tamaño de bloque unidimensional de 256 threads. Además, obtendremos el speedup comparando con la medición secuencial.

Solver	Tipo	T (s)	Speedup
Runge Kutta	Secuencial	2531.01	1
	OMP	236.42	10.70556636
	CUDA	77.1447	32.80860513
Adams-Bashforth	Secuencial	847.87	1
	OMP	82.704	10.25186206
	CUDA	23.5544	35.99624699
Adams-Bashforth-Moulton	Secuencial	2692.79	1
	OMP	264.402	10.18445398
	CUDA	86.2916	31.20570252

Tabla 4.1: Comparativa con Brusselator2D 125K entre tecnologías

Si bien sí podemos calcular el speedup, no tiene sentido calcular la eficiencia, ya que las hebras GPU y las hebras CPU no son comparables. En cualquier caso, podemos apreciar una ganancia en velocidad similar al pasar a CUDA con cualquiera de los métodos.




Figura 4.4: Comparativa con Brusselator2D 125K entre tecnologías

Si nos centramos ahora en el desempeño de las versiones CUDA a través de varios tamaños de problema, por ejemplo, el método Runge-Kutta de orden 4 aplicado a los problemas AdvDiff1D, y Brusselator1D:

neqn	T (s)	ms/eq	neqn	T (s)	ms/eq	neqn	T (s)	ms/eq
50	27.43	548.6	20K	51.70	2.585	200K	270.13	1.350
100	21.42	214.2	30K	53.40	1.780	250K	340.20	1.360
200	28.72	143.6	40K	73.87	1.846	300K	411.62	1.372
500	31.04	62.08	50K	73.45	1.469	350K	484.81	1.385
1K	30.87	30.87	75K	115.03	1.533	400K	542.48	1.356
2K	31.22	15.61	100K	134.52	1.345	450K	615.77	1.368
5K	31.21	6.243	125K	179.36	1.434	500K	687.30	1.374
10K	31.14	3.114	150K	202.54	1.350	750K	1044.1	1.392
15K	32.79	2.186	175K	247.07	1.411	1M	1375.4	1.375

Tabla 4.2: Mediciones de RK4 a través de diferentes tamaños de AdvDiff1D en CUDA

neqn	T (s)	ms/eq	neqn	T (s)	ms/eq	neqn	T (s)	ms/eq
100	18.96	189.6	40K	28.27	0.706	400K	195.79	0.489
200	18.84	94.21	60K	33.41	0.556	500K	246.38	0.492
400	19.16	47.91	80K	38.56	0.482	600K	291.95	0.486
1K	17.08	17.08	100K	43.40	0.434	700K	335.23	0.478
2K	17.09	8.548	150K	68.54	0.456	800K	379.27	0.474
4K	17.20	4.300	200K	89.16	0.445	900K	423.52	0.470
10K	17.43	1.743	250K	115.64	0.462	1M	469.07	0.469
20K	22.30	1.115	300K	141.37	0.471	1.5M	702.06	0.468
30K	23.58	0.786	350K	173.56	0.495	2M	927.77	0.463

Tabla 4.3: Mediciones RK4 a través de diferentes tamaños de Brusselator1D en CUDA

O de forma gráfica, con el tiempo total en azul y en el eje Y logarítmico, y el tiempo empleado por ecuación en naranja y el eje Y derecho logarítmico:




Figura 4.5: Mediciones de RK4 a través de diferentes tamaños de AdvDiff1D en CUDA




Figura 4.6: Mediciones RK4 a través de diferentes tamaños de Brusselator1D en CUDA

Aquí podemos apreciar dos dinámicas distintas interactuando entre ellas en ambas mediciones experimentales. Por un lado, observando la línea del tiempo (azul) vemos como para tamaños pequeños, la parte secuencial del problema **domina la ejecución**, y el tiempo paralelo es casi cero, lo que implica que el total prácticamente no varía (o incluso disminuye) con respecto al aumento de tamaño hasta llegar a un tamaño en torno a 50K ecuaciones. A partir de esa cifra es cuando la GPU puede empezar a trabajar de forma **eficiente**, y el tiempo aumenta de forma lineal. Esto coincide con lo esperado.

Por otro lado, si observamos la curva naranja, de tiempo por ecuación (en milisegundos), vemos el efecto contrario. Conforme aumenta el tamaño del problema y la GPU puede trabajar con más ecuaciones, este cociente se reduce conforme aumenta el número de ecuaciones. Sin embargo, a partir de cierto punto se **estabiliza**, que será cuando se alcanza la eficiencia máxima.

4.3. Uso de CUDA Graphs

Tras ver el bucle de ejecución de la función miembro `aplicar()`, salta a la vista que se llama a uno o varios kernels de forma repetitiva y con los mismos datos, con los mismos vectores, y sólo varía la variable del tiempo. A raíz de esto se decide implementar una nueva versión de las clases métodos, que utilice los *CUDA Graph*.

Los CUDA Graphs son una representación estática de un conjunto de operaciones CUDA (kernels, copias, eventos) con sus dependencias. [Barlas, 2023] Se capturan una vez y se ejecutan muchas veces con **mínimo overhead**. Está formado por nodos que representan las operaciones realizadas, y edges que representan dependencias de ejecución.

El funcionamiento es relativamente simple, se capturan una secuencia de operaciones (`cudaStreamCapture`), se analizan las dependencias y se optimiza el grafo, se instancia(`cudaGraphInstantiate`), y se ejecuta (`cudaGraphLaunch`) tantas veces como se desee [NVIDIA, 2026].

Los graph CUDA presentan ciertas ventajas, como la reducción en el overhead del lanzamiento de kernels, la **optimización de las dependencias**, o la fusión interna de nodos. Algunas de sus limitaciones es que la estructura del grafo debe ser estática, o que no se pueden cambiar punteros capturados, ni introducir ramas dinámicas.

Para poder implementar los graph tuvimos que ampliar nuestro diagrama de clases, a saber, resumidamente:




Figura 4.7: Dependencias entre las clases Graph

Se han creado nuevas clases "**problema_graph**" que heredan de las anteriores para reutilizar todos sus métodos salvo *aplicar()*, que lo sobrescriben. Dentro de él, capturan el grafo y lo lanzan las veces necesarias, pero con un detalle. Ya mencionamos que los kernel del bucle **for** eran iguales en cada iteración salvo por el tiempo (t_n) que sí cambiaba con cada iteración. Para tener esto en cuenta, cada vez que se va a lanzar el grafo se ha de modificar el objeto t_n a través de `cudaMemcpyToSymbolAsync` y la nueva función `get_t()`.

Por otro lado, también se modificaron los `feval()` de los problemas para adecuarlos a la implementación con CUDA Graph. En este caso, simplemente se sobrecargó el método `feval()`. Estos métodos a su vez, en lugar de llamar al kernel ya conocido, llamarán a un nuevo kernel también adaptado para los CUDA Graph.

neqn	T(s) - CON	T(s) - SIN	Cociente
1250	15.6045	15.7724	1.010759717
5000	15.3411	15.7544	1.026940702
11250	15.9351	16.1561	1.013868755
20000	22.6578	22.6586	1.000035308
31250	23.8161	23.6049	0.991132049
45000	31.6381	30.7777	0.972804941
61250	39.9935	39.1357	0.978551515
80000	47.0315	43.5740	0.926485441
101250	69.7740	62.0139	0.888782354
125000	99.3000	86.2916	0.868998993
180000	147.217	120.547	0.818838857
320000	264.624	213.418	0.806495254
500000	392.972	313.984	0.798998402
720000	573.024	458.030	0.799320796
980000	772.954	615.165	0.795862367

Tabla 4.4: Comparación de tiempos de CUDA Graph con ABM5 en Bruselator2D

Sin embargo, como podemos ver en los resultados de nuestras mediciones, la introducción de los *Graph* no solo no representó una mejora en los tiempos, sino que conforme aumentaban los tamaños, se estabilizaba en quedar un 20 % más lenta que la versión sin *Graph*.




Figura 4.8: Comparación de tiempos de CUDA Graph con ABM5 en Bruselator2D

Esto puede deberse a que el uso de CUDA Graphs sólo acelera la ejecución cuando el overhead de lanzamiento de kernels es significativo respecto

al coste del kernel, como por ejemplo cuando los kernels son muy rápidos y el lanzamiento es costoso, pero como los nuestros son relativamente pesados (principalmente por sus múltiples accesos a memoria global), pues se da el caso de que el *Graph* cuesta más de lo que ahorra.

4.4. Shuffles y Grids multidimensionales

Para intentar minimizar los **accesos a memoria** dentro de lo posible, se hace uso de otra herramienta que CUDA pone a nuestra disposición, los *shuffle*. Los **warp shuffle** son instrucciones a nivel de warp que permiten que un hilo lea el valor de un registro de otro hilo del mismo warp.

Cada hilo llama a la misma función, pero puede recibir el valor de otro hilo del warp según el patrón especificado. A nivel de hardware, esto se implementa mediante una red de interconexión interna del warp (*warp crossbar*) que mueve datos entre registros sin tener que pasar por la memoria global, lo cual reduce los accesos, y por tanto el tiempo de ejecución del kernel.

Aunque el programador define a través del **blocksize** el tamaño de los bloques que forman el grid (por ejemplo, un tamaño habitual sería un bloque unidimensional de 256 hebras), a nivel de hardware CUDA se organiza en warps de 32 hilos consecutivos que se mueven al unísono, y es entre ellos donde ocurre la comunicación que permiten los *shuffle*.




Figura 4.9: Ejemplo de shuffle down [Luitjens, 2014]

La imagen ilustra un ejemplo de shuffle. Los hilos crean una variable local *i* (en este caso su propio identificador dentro del warp), y a través del shuffle podrán accederse entre ellos a esa variable. En este caso, cada hilo accede a esa variable *i* de los vecinos situados dos hilos por encima, y copia el contenido de la variable del vecino en una nueva variable propia llamada *j*.

Esto resulta útil en implementaciones como el algoritmo 11, en el que un mismo thread hace varios accesos a memoria global, y esto podríamos sustituirlo por un único acceso a memoria global, y varios shuffle entre hilos.

Algoritmo 13 Kernel feval de AdvDiff1D con shuffle

```
thread  $\leftarrow$  blockDim.x · blockIdx.x + threadIdx.x
ult  $\leftarrow$  cte_avd1.neqn − 1
lane  $\leftarrow$  threadIdx.x & 31 ▷ Posicion en el warp
if thread < cte_avd1.neqn then
    mask = 0xFFFFFFFF
    valor  $\leftarrow$  Y[thread] ▷ Acceso a memoria
    val_ant  $\leftarrow$  __shfl_up_sync (mask, valor, 1) ▷ Valores vecinos
    val_pst  $\leftarrow$  __shfl_down_sync (mask, valor, 1)
    if lane == 0 || thread == 0 then ▷ Corrección de valores frontera
        val_ant  $\leftarrow$  (thread == 0) ? Y[ult] : Y[thread − 1]
    end if
    if lane == 31 || thread == ult then
        val_pst  $\leftarrow$  (thread == ult) ? Y[0] : Y[thread + 1]
    end if
    DY[thread]  $\leftarrow$  Cálculo usando val_ant, valor, val_pst, thread, t, cte_avd1
end if
```

En este ejemplo, en lugar de que cada hilo acceda 3 veces a memoria, acceden una sola, y es en los casos frontera en los que se hacen accesos extra puntuales.

Para lograr esta implementación se crean nuevas clases `problema_shuffle` que heredan de las clases estándar, sobrecargan la función miembro `feval`, e implementan su propia versión del kernel.

También se ha realizado otra nueva implementación aplicando otra innovación distinta de CUDA, los grid multidimensionales. Como pudimos ver en el algoritmo 8, a la hora de llamar a un kernel se le ha de indicar tanto las dimensiones de la grid como de los bloques que ésta contiene. Si bien se pueden utilizar enteros básicos (que CUDA interpreta como valores unidimensionales), también podemos indicarle a CUDA que vamos a trabajar con grids multidimensionales.

Para poner esto en práctica, se crea una clase hija llamada `problema_grid` que hereda de la clase estándar, y sobrecarga las funciones `init()` y `feval()`, ya que la organización de los hilos será distinta de la que se tenía. En un problema como Brusselator1D, en el que cada elemento que lo compone tiene dos componentes, u y v , estas componentes pueden reinterpretarse como una segunda dimensión. Así se vería:

Algoritmo 14 Kernel feval de Brusselator1D con grid multidimensional

```
id_x ← blockDim.x · blockIdx.x + threadIdx.x           ▷ Coordenada X
id_z ← threadIdx.z                                     ▷ Coordenada Z
ult ← nx − 1
lane ← threadIdx.x & 31                                ▷ Posicion en el warp
thread ← id_y · nx + id_x
if id_x < nx && id_y < 2 && thread < neqn then
  valor ← Y[thread]
  mask = 0xFFFFFFFF
  val_izq ← __shfl_up_sync (mask, valor, 1)           ▷ Valores vecinos
  val_der ← __shfl_down_sync (mask, valor, 1)
  if lane == 0 || id_x == 0 then                       ▷ Corrección de valores frontera
    val_izq ← (id_x == 0) ? C : Y[thread − 1]
  end if
  if lane == 31 || id_x == ult then
    val_der ← (id_x == ult) ? C : Y[thread + 1]
  end if
  val_pareja ← (id_y == 0) ? Y[thread + nx] : Y[thread − nx]
  DY[thread] ← Cálculo usando val_izq, valor, val_der, thread, t...
end if
```

En la implementación original, los datos se almacenaban en bloques unidimensionales formando un **Array of Structures**.

$$[0_u, 0_v, 1_u, 1_v, \dots, (n-2)_u, (n-2)_v, (n-1)_u, (n-1)_v] \quad (4.1)$$

Mientras que en esta implementación cambiamos el paradigma a bloques bidimensionales que forman un **Structure of Arrays**.

$$[0_u, 1_u, \dots, (n-2)_u, (n-1)_u, 0_v, 1_v, \dots, (n-2)_v, (n-1)_v] \quad (4.2)$$

Sin embargo, yendo a las mediciones podemos ver que no ocurren **cam-bios significativos** con ninguna de las dos nuevas implementaciones frente a la anterior “estándar”.

neqn	T (s) de implementación			neqn	T (s) de implementación		
	Estándar	Shuffle	Grid		Estándar	Shuffle	Grid
200	4.25118	4.27395	4.40917	300000	49.0773	47.6186	47.1094
400	4.38250	4.47631	4.42845	400000	64.3164	64.0661	62.2658
1000	4.42428	4.48073	4.45638	500000	78.4998	79.2419	79.3901
2000	4.47256	4.49739	4.55980	600000	92.2143	93.8084	94.2763
4000	4.50782	4.55148	4.52020	700000	108.716	108.272	108.879
10000	4.64262	4.71993	4.68111	800000	123.306	122.247	122.502
20000	6.07753	6.19400	6.26689	900000	137.599	136.730	137.174
40000	7.65326	7.71357	7.82265	1000000	152.187	151.235	151.697
80000	10.92320	10.54850	10.69110	1200000	180.576	179.841	180.080
100000	13.19100	12.06130	12.23360	1400000	209.347	208.619	209.053
150000	23.07470	21.85070	22.02480	1600000	238.003	237.406	237.448
200000	30.91270	29.03480	29.69920	1800000	267.296	266.385	266.490
250000	41.32400	37.76580	38.72750	2000000	296.847	294.948	295.242

Tabla 4.5: Tiempos de AB4 en Brusselator1D estándar, Shuffle y Grid

Estos resultados concuerdan con lo esperado, teniendo en cuenta la naturaleza de los problemas con los que hemos trabajado y los cambios implementados. Si bien con otro tipo de problemas podrían ser beneficiosos cambios de ésta índole, en los nuestros las mejoras de tiempo de computación están limitadas por el ancho de banda de memoria global, la latencia de VRAM, y la coalescencia de accesos.




Figura 4.10: Tiempos de AB4 en Brusselator1D estándar, Shuffle y Grid

Capítulo 5

Planificación

A la hora de realizar un proyecto de esta magnitud, la planificación es de suma importancia, ya que a fin de cuentas es el pilar en el que se vertebra el proyecto, y que dicta qué se debe ir haciendo en cada momento. La planificación aquí expuesta ha permitido cumplir los objetivos inicialmente establecidos.

- Abril: Definición del proyecto
 - Identificación del tema a desarrollar
 - Formulación de los objetivos
- Mayo: Investigación
 - Recopilación y revisión de libros y papers relevantes
 - Búsqueda de información sobre las dos tecnologías de paralelización
- Junio: Implementación de OpenMP
 - Secuencial
 - Paralelismo por operaciones
 - Paralelismo por componentes
 - Pruebas y validación del código
- Julio: Implementación de CUDA
 - Desarrollo de los kernels
 - Kernels Graph
 - Shuffles y grids
 - Pruebas y validación del código
- Agosto: Memoria del proyecto

- Mediciones temporales
 - Análisis de los datos
 - Redacción de la memoria
- Septiembre: Entrega
- Últimas correcciones
 - Presentación y defensa




Figura 5.1: Diagrama de Gantt

Capítulo 6

Código fuente

El código desarrollado, así como las diferentes partes que componen esta memoria se encuentran en el siguiente repositorio:

<https://github.com/PepeNavarro7/TFG>

GitHub es una plataforma online donde los desarrolladores almacenan, comparten y colaboran en proyectos de programación usando Git, que es un sistema de control de versiones distribuido, que sirve para guardar el historial de un proyecto, comparar versiones, volver atrás, trabajar en paralelo y fusionar cambios sin perder nada.

Para usar el proyecto, basta con descargar cualquiera de las dos carpetas del solver (OpenMP o CUDA), y ejecutar el Makefile siguiendo las instrucciones que vienen dentro del mismo, que permiten la ejecución de un solo test, o de una batería de ellos.

Para las mediciones que se muestran en el presente proyecto se utilizó ese mismo código fuente ejecutado desde el sistema *ILEX* perteneciente a la Universidad de Granada.

Bibliografía

- [Amdahl, 1967] Amdahl, G. M. (1967). Validity of the single processor approach to achieving large scale computing capabilities. In *Spring Joint Computer Conference*. <https://dl.acm.org/doi/10.1145/1465482.1465560>.
- [ARB, 2024] ARB, O. (2024). Openmp 6.0 api syntax reference guide directives and constructs. <https://www.openmp.org/resources/refguides/>.
- [Ascher and Petzold, 1998] Ascher, U. M. and Petzold, L. R. (1998). *Computer Methods for Ordinary Differential Equations and Differential-Algebraic Equations*. SIAM.
- [Barlas, 2023] Barlas, G. (2023). *Multicore and GPU Programming, An Integrated Approach*. Morgan Kaufman Publisher, second edition.
- [Beard, 2020] Beard, T. (2020). Cuda memory hierarchy. <http://thebeardsage.com/cuda-memory-hierarchy/>.
- [Burden et al., 2016] Burden, R. L., Faires, D. J., and Burden, A. M. (2016). *Numerical analysis*. Cengage Learning, decima edition.
- [Calcs, 2023] Calcs, W. (2023). How to do euler’s method? <https://calcworkshop.com/first-order-differential-equations/eulers-method-table/>.
- [Casas, 2024] Casas, A. (2024). Cuda tutorial – introduction to blocks and grids. <https://blog.damavis.com/en/cuda-tutorial-blocks-and-grids/>.
- [Chapman et al., 2007] Chapman, B., Jost, G., and der Pas, R. V. (2007). *Using OpenMP: Portable Shared Memory Parallel Programming (Scientific and Engineering Computation)*. The MIT Press.
- [Farber, 2011] Farber, R. (2011). *CUDA Application Design and Development*. Morgan Kaufman.
- [Gallardo, 2018] Gallardo, J. M. (2018). *Análisis Numérico de Ecuaciones Diferenciales, Teoría y ejemplos con Python*. Universidad de Málaga.

- [Grama et al., 2003] Grama, A., Gupta, A., Karypis, G., and Kumar, V. (2003). *Introduction to Parallel Computing*. Addison Wesley, second edition.
- [Griffiths and Higham, 2010] Griffiths, D. F. and Higham, D. J. (2010). *Numerical Methods for Ordinary Differential Equations, Initial Value Problems*. Springer Undergraduate Mathematics Series Advisory Board.
- [Gustafson, 1988] Gustafson, J. (1988). Reevaluating amdahl’s law. *Communications of the ACM*, 31. <http://www.johngustafson.net/pubs/pub13/amdahl.pdf>.
- [Hairer et al., 1993] Hairer, E., Norsett, S. P., and Wanner, G. (1993). *Solving Ordinary Differential Equations I, Nonstiff Problems*. Springer Berlin Heidelberg, second revised edition.
- [Heath, 2002] Heath, M. T. (2002). *Scientific Computing: An Introductory Survey*. McGraw-Hill Higher Education, second edition.
- [Jin et al., 2024] Jin, H., Pophale, S., and Milfeld, K. (2024). *OpenMP Application Programming Interface Examples*. OpenMP Architecture Review Board, 6.0 edition. <https://www.openmp.org/wp-content/uploads/openmp-examples-6.0.pdf>.
- [Kim, 2026] Kim, S. (2026). *Numerical Methods for Partial Differential Equations*. Mississippi State University.
- [Kirk and Hwu, 2010] Kirk, D. B. and Hwu, W. W. (2010). *Programming Massively Parallel Processors, A Hands-on Approach*. Morgan Kaufman.
- [Kostler et al., 2006] Kostler, H., Deserno, F., and Moller, C. (2006). Performance results for optical flow on an opteron cluster using a parallel 2d/3d multigrid solver. Technical report, Friedrich-Alexander-Universitat Erlangen-Nurnberg Institut fur Informatik. <https://www.researchgate.net/publication/236892123>.
- [Lawrence, 2019] Lawrence, L. N. L. (2019). Openmp programming model. <https://hpc-tutorials.llnl.gov/>.
- [Luitjens, 2014] Luitjens, J. (2014). Faster parallel reductions on kepler. <https://developer.nvidia.com/blog/faster-parallel-reductions-kepler/>.
- [Mantas, 2024] Mantas, J. M. (2024). Vssbdf: Variable stepsize semi-implicit backward differentiation formula solvers in c++. <https://github.com/jmmantas/VSSBDF>.
- [Mara’beh et al., 2024] Mara’beh, R. A., Mantas, J. M., González, P., and Spiteri, R. J. (2024). Performance comparison of variable-stepsizes imex

- sbdf methods on advection-diffusion-reaction models. *Computers and Mathematics with Applications*.
- [Molero et al., 2007] Molero, M., Salvador, A., Menarguez, T., and Garmendia, L. (2007). *Análisis Matemático para Ingeniería*. Pearson Educación.
- [NVIDIA, 2026] NVIDIA (2026). *CUDA Programming Guide*. NVIDIA, 13.3 edition. <https://docs.nvidia.com/cuda/cuda-programming-guide/index.html>.
- [Nyandieka and Segera, 2023] Nyandieka, O. M. and Segera, D. R. (2023). A chaotic multi-objective runge-kutta optimization algorithm for optimized circuit design. *Mathematical Problems in Engineering*, 2023. <https://onlinelibrary.wiley.com/doi/10.1155/2023/6691214>.
- [Schryen, 2024] Schryen, G. (2024). Speedup and efficiency of computational parallelization: A unifying approach and asymptotic analysis. *Journal of Parallel and Distributed Computing*, 187. <https://www.sciencedirect.com/science/article/pii/S0743731523002058>.
- [Segarra-Escandon, 2020] Segarra-Escandon, J. (2020). Metodos numericos, runge-kutta y adams bashford-moulton en mathematica. *Revista Ingeniería, Matemáticas y Ciencias de la Información*, 7:13–32. <https://ojs.urepublicana.edu.co/index.php/ingenieria/article/view/639/507>.
- [Shiang et al., 2016] Shiang, W. C., Aziz, I. A., Haron, N. S., Jaafar, J., Ismail, N. N., and Mehat, M. (2016). The high performance linpack (hpl) benchmark evaluation on utp high performance cluster computing. *Jurnal Teknologi Sciences & Engineering*, 78. <https://www.researchgate.net/publication/309529380>.
- [Wilkinson and Allen, 2005] Wilkinson, B. and Allen, M. (2005). *Parallel programming, techniques and applications using networked workstations and parallel computers*. Pearson/Prentice Hall, second edition.
- [Zill, 2009] Zill, D. G. (2009). *Ecuaciones diferenciales con aplicaciones de modelado*. Brooks/Cole, Cengage Learning, novena edition.

Listado de Algoritmos

1.	Runge-Kutta de Orden 4	16
2.	Adams-Bashforth general de orden k	18
3.	Adams-Bashforth-Moulton de orden k	20
4.	Kernel de vectorCopia	25
5.	Implementación de AB4 con Paralelismo por Operaciones . .	30
6.	Implementación de Función Auxiliar vectorCopia	30
7.	Implementación de AB4 con Paralelismo por Componentes .	32
8.	Implementación de feval CUDA	40
9.	Declaración del struct constante	41
10.	Función updateConstants() de Brusselator1D	42
11.	Kernel feval de AdvDiff1D	42
12.	Aplicar para el método Runge-Kutta de orden 2 en CUDA .	43
13.	Kernel feval de AdvDiff1D con shuffle	52
14.	Kernel feval de Brusselator1D con grid multidimensional . . .	53

Listado de Figuras

2.1. Aplicación del método de Euler [Calcs, 2023]	7
2.2. Comparativa entre la aproximación con Euler y valor real . .	9
2.3. Representación gráfica de la Ley de Amdahl [Shiang et al., 2016]	11
2.4. Representación gráfica de la Ley de Gustafson [Kostler et al., 2006]	13
2.5. Demostración gráfica de RK4 [Nyandieka and Segeera, 2023] .	15
2.6. Modelo <i>fork-join</i> [Lawrence, 2019]	21
2.7. Jerarquía de memorias en CUDA [Beard, 2020]	23
2.8. Grids y bloques CUDA [Casas, 2024]	25
3.1. Diagrama de Clases de los problemas en la implementación usando OpenMP	28
3.2. Diagrama de Clases de los métodos de resolución en la implementación usando OpenMP	29
3.3. Brusselator1D 100.000 ecuaciones	35
3.4. SimpleAdv 100.000 ecuaciones	35
3.5. ABM4 resolviendo Brusselator2D	37
3.6. Speedup y Eficiencia - ABM4 Brusselator2D	37
4.1. Diagrama de Clases CUDA para los problemas	40
4.2. Diagrama de Clases de los structs constantes	41
4.3. Diagrama de Clases de los Métodos en la versión CUDA . . .	43
4.4. Comparativa con Brusselator2D 125K entre tecnologías . . .	45
4.5. Mediciones de RK4 a través de diferentes tamaños de Adv-Diff1D en CUDA	47
4.6. Mediciones RK4 a través de diferentes tamaños de Brusselator1D en CUDA	47
4.7. Dependencias entre las clases Graph	49
4.8. Comparación de tiempos de CUDA Graph con ABM5 en Brusselator2D	50
4.9. Ejemplo de shuffle down [Luitjens, 2014]	51
4.10. Tiempos de AB4 en Brusselator1D estándar, Shuffle y Grid .	54

5.1. Diagrama de Gantt	56
----------------------------------	----

Listado de Tablas

2.1. Comparativa entre la aproximación con Euler y valor real . .	8
3.1. Mediciones experimentales de SimpleAdvDiff y Brusselator1D con 100000 ecuaciones	34
3.2. Brusselator2D con ABM4	36
4.1. Comparativa con Brusselator2D 125K entre tecnologías . . .	45
4.2. Mediciones de RK4 a través de diferentes tamaños de Adv- Diff1D en CUDA	46
4.3. Mediciones RK4 a través de diferentes tamaños de Brussa- tor1D en CUDA	46
4.4. Comparación de tiempos de CUDA Graph con ABM5 en Brusselator2D	50
4.5. Tiempos de AB4 en Brusselator1D estándar, Shuffle y Grid .	54